

Análise

Previsão baseada em inteligência artificial do risco do pé diabético em Pacientes com Diabetes: Uma Revisão da Literatura

Lucija Gosak ^{1,*} , Adrijana Svenssek ¹, Mateja Lorber ¹  e Gregor Stiglic ^{1,2,3} 

¹ Faculdade de Ciências da Saúde, Universidade de Maribor, 2000 Maribor, Eslovênia

² Faculdade de Engenharia Elétrica e Ciência da Computação, Universidade de Maribor, 2000 Maribor, Eslovênia

³ Instituto Usher, Universidade de Edimburgo, Edimburgo EH8 9YL, Reino Unido

* Correspondência: lucija.gosak2@um.si; Tel.: +386-2-300-4735

Resumo: O pé diabético é uma complicação crônica prevalente do diabetes e aumenta o risco de amputação de membros inferiores, levando a um problema econômico e social importante. Ao detectar o risco de desenvolver pé diabético suficientemente cedo, este pode ser prevenido ou pelo menos adiado. Usando a inteligência artificial, o atraso no diagnóstico pode ser evitado, levando a um tratamento preventivo mais intensivo dos pacientes. Com base em uma revisão sistemática da literatura, analisamos 14 artigos que incluíam o uso de inteligência artificial para prever o risco de desenvolver pé diabético. Os artigos eram altamente heterogêneos em termos de uso de dados e apresentavam graus variados de sensibilidade, especificidade e precisão. As técnicas de aprendizado de máquina mais utilizadas foram Support Vector Machine (SVM) (n = 6) e K-Nearest Neighbor (KNN) (n = 5). Pesquisas futuras são recomendadas em amostras maiores de participantes, utilizando diferentes técnicas para determinar a mais eficaz.

Palavras-chave: inteligência artificial; aprendizado de máquina; termografia; previsão de pé diabético; diabetes; cuidados com diabetes; pé diabético; revisão da literatura



Citação: Gosak, L.; Svenssek, A.; Lorber, M.; Stiglic, G. Previsão Baseada em Inteligência Artificial de Risco de pé diabético em pacientes com Diabetes: uma revisão da literatura. *Apl. Ciência*. **2023**, *13*, 2823. <https://doi.org/10.3390/app13052823>

Editores Acadêmicos: Zimi Sawacha e Álvaro Astásio Picado

Recebido: 19 de dezembro de 2022

Revisado: 7 de fevereiro de 2023

Aceito: 21 de fevereiro de 2023

Publicado: 22 de fevereiro de 2023



Direitos autorais: © 2023 dos autores.

Licenciado MDPI, Basileia, Suíça.

Este artigo é um artigo de acesso aberto distribuído nos termos e

condições do Creative Commons

Licença de atribuição (CC BY) (<https://creativecommons.org/licenses/by/4.0/>).

1. Introdução

O diabetes mellitus (DM) é uma doença crônica que requer monitoramento e manejo constantes, e não apenas controle da glicemia. Em todo o mundo, cerca de 422 milhões de pessoas têm diabetes, a maioria delas em países de baixo e médio rendimento, e 1,5 milhões de mortes por ano estão diretamente relacionadas com a diabetes [1]. A doença provoca diversas complicações crônicas que podem ter um impacto significativo na qualidade de vida dos pacientes, onerar o sistema de saúde através de hospitalizações e contribuir para o aumento da mortalidade [2]. Espera-se que muitas pessoas com diabetes desenvolvam úlceras no pé diabético (DFU) [3], o que causa uma alta taxa de amputações em pacientes diabéticos [4], geralmente devido ao mau controle glicêmico, neuropatia subjacente, doença vascular periférica ou cuidados inadequados com os pés. A DFU pode ocorrer em qualquer idade, mas é mais comum em pacientes diabéticos com 45 anos ou mais [5]. As taxas de mortalidade associadas ao desenvolvimento do pé diabético são estimadas em 5% nos primeiros 12 meses e 42% aos 5 anos [6]. A incidência anual de úlceras de pé diabético em todo o mundo está entre 9,1 e 26,1 milhões [5,7].

As características de uma DFU, como localização anatômica, profundidade da ferida, infecção e isquemia da lesão no pé na apresentação, bem como o controle glicêmico, influenciam o resultado [8–10]. Pessoas com maior risco de úlceras podem ser identificadas por um exame clínico dos pés [11]. Portanto, estratégias de prevenção, incluindo exames anuais do pé diabético, foram implementadas para permitir a identificação precoce de pacientes diabéticos com alto risco de complicações no pé diabético [12]. Prever quem desenvolverá uma úlcera significa que as terapias preventivas podem ser direcionadas de forma adequada [13]. A classificação da gravidade da úlcera é crucial no tratamento de pacientes com DFU e tem sido relatado que tem um impacto maior no sucesso final do tratamento do que o local da úlcera [8,14].

A inteligência artificial (IA) inclui uma descrição do uso de computadores e tecnologia para simular comportamento inteligente e pensamento crítico [15]. Diferentes métodos lidam com

quantidades diferentes e crescentes de dados de saúde, permitindo maior autonomia do paciente e tratamento personalizado [16]. Algumas pesquisas foram realizadas para diagnosticar e prever o diabetes mellitus e suas complicações, como o pé diabético [17]. A automação da gestão da saúde levou a uma transformação no campo pela introdução de soluções baseadas em inteligência artificial, devido à facilidade de coleta de dados em massa e ao poderoso processamento computacional. Tem o potencial de prevenir atrasos no diagnóstico e identificar tratamentos preventivos [18]. A prática clínica pode usar esses modelos preditivos para melhor determinar quais pessoas com diabetes de alto risco devem ser monitoradas mais de perto e tratados mais intensamente [19]. A termografia também é um dos métodos não invasivos que pode ser usado para prever riscos, pois as diferenças de temperatura no pé podem indicar problemas associados ao pé diabético [20].

O objetivo desta revisão rápida é responder à questão de pesquisa: quais técnicas de IA são mais eficazes na previsão do risco de desenvolver pé diabético?

2. Materiais e métodos

Uma revisão da literatura [21,22] foi usada para descrever as atuais abordagens baseadas em IA para previsão de diabetes e pé diabético. A primeira etapa incluiu uma revisão dos dados científicos literatura sobre modelos preditivos para risco de úlcera no pé diabético usando as palavras-chave e sinônimos úlceras do pé diabético, modelo de predição e inteligência artificial. A pesquisa completa a sequência era ("pé diabético" OR "úlceras do pé diabético") AND ("inteligência artificial" OR IA OU "modelos preditivos" OU "modelagem preditiva" OU "modelo de previsão"). Baseado nas palavras-chave e na string de busca, foi realizada uma revisão sistemática da literatura em nas seguintes bases de dados: PubMed, CINAHL/MEDLINE, Web of Science, Scopus e SÁBIO. Também revisamos a pesquisa relevante no Google Scholar. Na próxima etapa, dois os revisores selecionaram independentemente os títulos e resumos e os analisaram de acordo com os critérios de inclusão/exclusão. Todos os tipos de artigos de pesquisa em inglês foram incluídos. Nós foram excluídos duplicados, comentários, livros, protocolos, editoriais, etc. incluídos no acompanhamento foram baixados na íntegra e triados.

Os artigos analisados foram apresentados por meio de uma tabela de características (autor, ano, estudo objetivo, amostra, estratégias de coleta de dados, técnicas, principais achados e limitações). Baseado no conteúdo dos artigos, dividimos-os em dois grupos: artigos para previsão de risco de pé diabético com base em um modelo de previsão e artigos para prever o risco de pé diabético com base na termografia. Com base na revisão da literatura e na análise de artigos, obtivemos apresentou uma representação gráfica das técnicas de IA mais utilizadas.

3. Resultados

Com base na string de pesquisa e considerando as limitações da pesquisa, os seguintes resultados foram extraídos das bases de dados (Tabela 1): PubMed (n = 152), CINAHL/MEDLINE (n = 134), Scopus (n = 118), SAGE (n = 75) e Web of Science (n = 121).

Tabela 1. Pesquisas na base de dados.

#	Palavras-chave	PubMed	MEDLINE/ CINAHL	Rede de Ciência	Escopo	SÁBIO
1	("pé diabético" OU "pé diabético úlceras")	14.752	26.197	13.055	21.671	2844
2	("inteligência artificial" OU IA OU "modelos preditivos" OU "modelos preditivos modelagem" OU "modelo de previsão")	1.138.539	277.910	955.062	726.455	30.477
3	("pé diabético" OU "pé diabético úlceras") E ("inteligência artificial" OU IA OU "modelos preditivos" OU "modelagem preditiva" OU "previsão modelo")	152	134	121	118	75

Após uma pesquisa adicional no Google Scholar, adicionamos mais 12 relatórios. Então, realizamos o Rayyan, ferramenta computacional para remoção de duplicatas (n=310). Selecionamos o restante artigos (n=290) e excluímos artigos que não tinham DFU previsto ou que não tinham um texto completo, não trazia sobre inteligência artificial e artigos escritos em outros idiomas. Por fim, 14 estudos foram incluídos na análise (Figura 1).

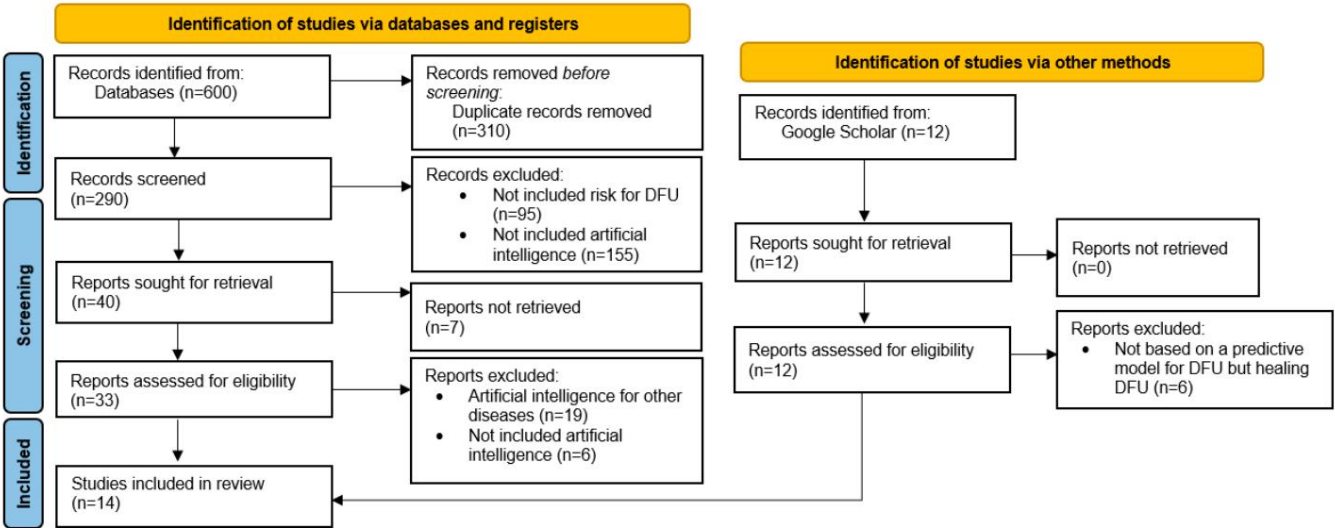


Figura 1. Fluxograma PRISMA.

A Tabela 2 apresenta as características básicas dos estudos incluídos.

Tabela 2. Características básicas dos estudos incluídos.

Autor, Ano	Objetivo do estudo	Amostra	Coleção de dados Estratégias	Técnicas	Principais descobertas	Limitações
Artigos para prever o risco de pé diabético com base em um modelo de predição						
Ferreira et al., 2020 [23]	O objetivo deste estudo é identificar automaticamente pacientes com DM que apresentam alto risco de desenvolver pé diabético, por meio de uma técnica de aprendizado de máquina não supervisionada.	250 pacientes com diagnóstico de diabetes.	Os riscos foram registrados por enfermeiros especialistas com base em entrevista, questionário de hábitos de autocuidado, questionário sociodemográfico e Medidas.	Neurais Artificiais Rede (RNA)	<ul style="list-style-type: none">Em um treinamento de camada neural competitiva (CNL), é dada mais importância às variáveis mais discriminatórias e menos importância às variáveis menos discriminatórias. • O método RNA foi validado com base em dados de testes disponíveis e alcançou uma sensibilidade de 71%, uma especificidade de 100% e uma precisão de 90%. • O algoritmo proposto sugeriu as variáveis mais importantes. Essas variáveis são idade, tipo de diabetes, índice de massa corporal, controle alimentar, atividade física, tabagismo, presença de hipertensão e problemas circulatórios, sensação de choque nos pés e pernas, presença de joanetes, alterações na visão, problemas com o hábito de lavar nos pés, presença de espinhas nos pés e presença de ferimento e/ou amputação.	Os autores apontam a limitação devido às informações subjetivas obtidas dos pacientes com diabetes. Eles ressaltam ainda que os resultados da pesquisa não comprovaram se os pacientes classificados como de risco para desenvolver diabetes realmente desenvolveram pé diabético.
Nanda et al., 2022 [24]	Este estudo tem como objetivo descobrir a associação entre vários e risco bioquímico fatores e DFU usando diferentes algoritmos de aprendizado de máquina. Oitenta pacientes com diabetes mellitus tipo 2 (DM2) com DFU e DM2 sem DFU foram inscritos para este estudo observacional.	160 pacientes, dos quais 80 pacientes com diagnóstico de diabetes tipo 2 com DFU e 80 pacientes com diagnóstico de diabetes tipo 2 sem DFU.	Os pacientes com DFU foram classificados com base no sistema de classificação de Wagner para úlceras. Os dados foram baseados em amostra de sangue (5 mL) para GPJ, PPPG, perfil lipídico, testes de função renal, HbA1C, ApoA1 e citocinas como IL-10 e TNF-γ.	Vetor de suporte Máquina (SVM), K-vizinho mais próximo (KNN), Naive Bayes (Obs.)	<ul style="list-style-type: none">Foram identificados novos factores de risco, como ApoA1 e IL-10, para o desenvolvimento de DFU na diabetes. A IL-10 junto com o ácido úrico poderia discriminar as taxas de úlcera de acordo com sua gravidade. • VM-PolyK (0,875) e F-measure (0,938) superaram todos os outros algoritmos, seguidos de perto pelo RF, que foi superior ao SVM-PolyK em termos de área sob a curva (AUC: 0,969). • O desempenho de KNN e Naive Bayes é comparável entre si, pois ambos tiveram desempenho abaixo da floresta aleatória (RF) e do SVM-PolyK. • A estratégia de agrupamento de decisões utilizando o algoritmo Stacking C resultou em maior precisão de predição para ambos os níveis de classificação, o que pode ser utilizado como método complementar para triagem computacional de DFUs.	Os autores mencionam amostras pequenas como uma limitação.

Tabela 2. Cont.

Autor, Ano	Objetivo do estudo	Amostra	Estratégias de coleta de	Técnicas	Principais descobertas	Limitações
Ohura et al., 2019 [25]	Este estudo investigou se a segmentação de feridas de DFU e úlceras venosas de perna (UV) usando uma CNN é viável após treinamento com conjuntos de dados de úlceras por pressão (PU).	Dados de 440 pacientes (imagens de 400 úlceras de pressão, 20 úlceras de pé diabético e 20 úlceras venosas de perna).	dados As imagens foram extraídas de um banco de dados digital de imagens de feridas. As feridas foram fotografadas sob condições controladas de iluminação com câmeras a uma distância de aproximadamente 30 a 40 cm do plano da ferida.	CNN: SegNet, LinkNet, U-Net e U-Net_VGG16	<ul style="list-style-type: none">• CNNs com diferentes algoritmos e arquiteturas (SegNet, LinkNet, U-Net e U-Net com codificador VGG16 pré-treinado em ImageNet) foram produzidas. • O U-Net apresentou os melhores resultados, apresentando a segunda maior precisão em termos de área sob a curva (0,997) e alta especificidade (0,943) e sensibilidade (0,993).	Os dados são baseados em pacientes japoneses, portanto não podem ser generalizados para pacientes de outras raças.
Reddy et al., 2021 [26]	O objetivo deste estudo foi prever a DFU usando um algoritmo de rede neural eficaz em um conjunto de dados adequado que consiste em fatores de risco e resultados clínicos da doença.	133 ocorrências.	Os dados consistiam em 22 atributos (21 preditores, 1 alvo) obtidos do data warehouse.	Máquina de aprendizado extremo (ELM), vizinho K-mais próximo (KNN), máquina de vetores de suporte (SVM) com kernel gaussiano e rede neural artificial (RNA) também são considerados.	<ul style="list-style-type: none">• Cinco métricas de avaliação foram utilizadas para comparar os algoritmos: precisão, perda zero, Índice de Ameaça/Sucesso Crítico (TS/CSI), Taxa de Falha (FOR) e Taxa de Descoberta Falsa (FDR).• Após comparação, descobriu-se que o ELM superou o KNN, o SVM com kernel gaussiano e o ANN em termos de todas as métricas. • Os valores de precisão, perda de 0–1, TS/CSI, FOR e FDR obtidos para ELM são 96,15%, 0,0385, 0,95, 0 e 0,05, respectivamente.	Os autores recomendam que pesquisas futuras se concentrem em melhores técnicas para prever úlceras nos pés e outros efeitos colaterais e riscos associados ao diabetes.
Schäfer et al., 2020 [27]	Eles analisaram os dados de 246.705 pacientes com diabetes para avaliar alguns dos principais fatores de risco para o desenvolvimento de UPD/ amputação. Eles ainda usam técnicas de aprendizado de máquina para avaliar a utilidade prática de tais fatores de risco na previsão de úlceras nos pés e amputações.	246.705 pacientes com diabetes.	Os dados basearam-se em informações socioeconômicas e na história médica pregressa de pacientes nascidos entre 1900 e 1968, obtidas nos registros nacionais dinamarqueses.	Aplicando métodos de aprendizado de máquina: regressão logística (LR) e floresta aleatória (RF). Modelo estatístico: Modelo Cox Variável no Tempo (TVC), Modelo Aalen Johansen	<ul style="list-style-type: none">• Pacientes com menor renda familiar apresentam maior risco de desenvolver DFU. O modelo Cox PH estima a probabilidade condicional de desenvolver DFU ou amputação. Este modelo é útil para avaliar qualitativamente o aumento do risco devido a outras complicações. • O modelo de Aalen Johansen é uma abordagem não paramétrica para calcular a taxa de perigo cumulativa. Depois de avaliar os diferentes fatores de risco, o aprendizado de máquina é usado para prever a ocorrência de DFU/ amputação em diferentes intervalos de tempo. • Comparado com a tarefa de classificação, o ROC <p>curva mostra claramente pior desempenho. Com base nos resultados do classificador, os recursos utilizados no estudo podem ser utilizados para modelos preditivos, mas não são suficientes para prever com precisão a DFU/amputação.</p>	Os autores mencionam a necessidade de utilizar mais funções de engenharia e de obter mais informações sobre a área médica e história fisiológica dos pacientes.

Tabela 2. Cont.

Autor, Ano	Objetivo do estudo	Amostra	Coleção de dados Estratégias	Técnicas	Principais descobertas	Limitações
Tulloch et al., 2020 [28]	O objetivo deste estudo é avaliar a utilidade e precisão do aprendizado de máquina (ML) no cuidado intervencionista e tratamento de DFU.	37 artigos.	Revisão sistemática.	Neurais Artificiais Rede (RNA), Neural Convolucional Rede (CNN) e Vetor de suporte Máquina (SVM)	<ul style="list-style-type: none">Segmentação e classificação de imagens, análise de dados brutos e avaliação de riscos são aplicações em que o ML teve um impacto positivo na análise de dados e nos resultados da DFU. Em amostras e condições de estudo pequenas, o ML oferece uma solução eficiente e precisa para orientar a análise e extração de dados de intervenções destinadas ao cuidado de DFUs.Embora as redes neurais e os SVMs não possam ser treinados em grandes conjuntos de dados, eles podem atingir um alto nível de precisão e especificidade.	Os autores definem o viés metodológico como a principal limitação do estudo.
Zhang et al., 2022 [29]	Este estudo tem como objetivo prever a ocorrência e o prognóstico de DFUs com base em dados de angiografia por tomografia computadorizada (CTA) de membros inferiores e dados clínicos.	203 pacientes com úlceras de pé diabético (138 pacientes no grupo com baixo escore de Wagner e 65 pacientes no grupo com alto escore de Wagner).	Dados clínicos e de CTA de membros inferiores.	Modelo de redes neurais artificiais (RNA)	<ul style="list-style-type: none">Com base em dados clínicos e de ATC de membros inferiores, o modelo de RNA pode prever a ocorrência e o prognóstico de DFU. O desempenho global do modelo RNA apresentou sensibilidade de 92,3%, especificidade de 93,5%, valor preditivo positivo de 87,0%, valor preditivo negativo de 94,2% e área sob a curva de 0,955. A DFU foi prevista com 91,6% de precisão pelo modelo proposto. O VPP, o VPN e a sensibilidade do modelo foram calculados pela análise da amostra retida e foram de 88,9%, 90,0%, 88,5%, 75,0% e 95,8%, respectivamente. A RNA superou a regressão logística.As variáveis incluídas são idade, sexo, índice de massa corporal, duração do diabetes, duração da úlcera no pé diabético, sintomas nos membros, grau de estenose arterial dos membros inferiores, estenose arterial do segmento dos membros inferiores, calcificação arterial e comorbidades.	Os dados foram coletados de diferentes funcionários em diferentes hospitais. Hospitais individuais não possuíam equipamentos especializados para medir o índice tornozelo-braquial (ITB) dos pacientes.

Tabela 2. Cont.

Autor, Ano	Objetivo do estudo	Amostra	Coleção de dados Estratégias	Técnicas	Principais descobertas	Limitações
Artigos para prever o risco de pé diabético com base em termografia						
Cruz-Vega et al., 2020 [30]	Analisar o uso da inteligência artificial e do deep learning (DL) para a classificação dos termogramas do pé diabético e analisar as vantagens e limitações desse método.	110 termogramas de pacientes com diabetes.	Os dados foram obtidos de um banco de dados público de termogramas.	Perceptron multicamadas (MLP), Suporte Máquina vetorial (SVM), métricas de precisão (ACC), Neurais Artificiais Rede (RNA) e rede neural convolucional (CNN)	• Os resultados obtidos com o método DL tiveram melhor desempenho que os demais modelos e economizaram tempo, pois possuem um tempo de treinamento curto. Os resultados dos métodos CNN como GoogLeNet e AlexNet não foram satisfatórios. • O artigo propôs um novo design de CNN com estrutura simples, mas com design melhor. A DFTNet proposta fornece resultados satisfatórios com medidas de sensibilidade, especificidade, precisão e valores de AUC.	Os autores afirmam que pretendem obter mais imagens dos termogramas em estudos futuros.
Eid e outros, 2018 [31]	Propor um novo sistema para diagnóstico precoce do pé diabético utilizando imagens térmicas.	50 assuntos.	O banco de dados resultante consistia em 500 imagens.	K-vizinho mais próximo (KNN), Suporte Máquina vetorial (SVM) e Decisão Árvore	• O Fine KNN alcançou uma precisão máxima de 96,8%, uma sensibilidade de 88,3%, uma especificidade de 99,1% e uma pontuação de perda de 0,004. • O sistema proposto é preciso, com baixo tempo na fase de aprendizagem e testes, o que permite diagnosticar automaticamente o pé diabético e discriminá-los.	Os autores propõem incluir mais assuntos no estudo e classificar o sistema usando um algoritmo de aprendizagem profunda sem extração de características.
Filipe et al., 2022 [32]	Desenvolver uma metodologia funcional para análise e classificação de diferentes alterações térmicas na região plantar em indivíduos diabéticos e saudáveis, para possibilitar a utilização por profissionais de saúde em ambiente clínico.	167 indivíduos (122 com diabetes e 45 sem diabetes).	Conjunto de dados público de imagens térmicas.	Vetor de suporte Máquina (SVM) e K-vizinho mais próximo (KNN)	• Os dois modelos propostos tiveram um bom desempenho, mas comparado ao modelo 1 (termograma), o modelo 2 supera o modelo 1, pois permite uma melhor classificação de indivíduos saudáveis e diabéticos na primeira classe. • Os algoritmos SVM tiveram o segundo melhor desempenho com resultados semelhantes, seguido do algoritmo Weighted KNN; no entanto, isso foi melhor que o algoritmo 3-NN.	Os autores citam como limitação o fato de os dados obtidos do conjunto de dados público serem desequilibrados, resultando na sub-representação de algumas classes.

Tabela 2. Cont.

Autor, Ano	Objetivo do estudo	Amostra	Coleção de dados Estratégias	Técnicas	Principais descobertas	Limitações
Goyal et al., 2020 [33]	Propor aplicações de recursos tradicionais de visão computacional com classificação DFU. O problema de classificação DFU classifica a pele em duas classes: pele normal (pele saudável) e pele anormal (DFU).	292 imagens de pacientes com DFU.	Imagens coloridas do stpal de diferentes pacientes coletadas de um banco de dados dos últimos cinco anos do hospital. As imagens foram tiradas com uma Nikon D3300 a uma distância de aproximadamente 30–40 cm paralelamente ao plano da úlcera.	R-CNN mais rápido com InícioResNet V2, BayesNet, Aleatório Floresta, InceptionV3 e ResNet	<ul style="list-style-type: none">• Para identificar diferenças nas características entre pele saudável e DFU, foi proposta uma nova arquitetura de rede neural convolucional, DFUNet, que melhorou a extração de características.• Com validação cruzada de 10 vezes, DFUNet alcançou uma pontuação AUC de 0,961, superando o aprendizado de máquina testado e os classificadores de aprendizado profundo.	No futuro, os autores recomendam a desenvolvimento de um anotador automático que pode delinear e classificar automaticamente imagens dos pés sem a ajuda de médicos, o desenvolvimento da detecção, reconhecimento e classificação automática de úlceras usando esses classificadores e a implementação de um método para identificar diferentes patologias e realizar diferentes ferramentas de software fáceis de usar.
Gururajaroo et al., 2019 [34]	Apresentar o uso de técnicas de soft computing para análise de imagens médicas baseadas em termografia infravermelha, para avaliação de pacientes diabéticos complicações nos pés e os desafios que precisam ser enfrentados ao usar a termografia infravermelha para fins de diagnóstico.	62 pacientes com diabetes (38 homens e 24 mulheres) e 20 sem diabetes.	Dimensão da imagem 320 x 240 e 320 x 240 pixels.	Neurais Artificiais Rede (RNA)	<ul style="list-style-type: none">• O modelo RNA foi utilizado para prever o risco de pé diabético sem complicações, pé saudável ou pé diabético com complicações. Foi observada diferença de temperatura de 2,2 °C na presença de complicação. • A CNN classificou uma imagem de pé diabético sem complicações com probabilidade de 87,43%. Testando todas as imagens, foi alcançada uma precisão média de 91% para cada classe. • Embora 62 participantes diabéticos e 20 saudáveis tenham sido incluídos no estudo, não está claro como o desempenho da classificação foi calculado.	No futuro, os autores planejam desenvolver o modelo desde a etapa inicial para ter mais controle sobre o parâmetros para classificar e quantificar com maior precisão as taxas de complicações nas diferentes categorias.
	Apresentar uma nova abordagem de classificação holística que considera termogramas de indivíduos não diabéticos e diabéticos com base em uma CNN.					
Muralidhara et al., 2022 [35]		122 pacientes diabéticos e 45 controles.	Análise assimétrica em um padrão borboleta da distribuição de temperatura, onde a assimetria nesta distribuição indica uma anomalia. Os dados de análise foram coletados de um banco de dados disponível publicamente.	Rede neural convolucional (CNN)	<ul style="list-style-type: none">• Foi apresentada uma classificação multiclasse abrangente de imagens térmicas dos pés para predição e classificação de pacientes com diabetes mellitus. • O modelo obteve o melhor desempenho com uma precisão global de 0,9827, uma sensibilidade de linha de base de 0,9684 e uma especificidade de linha de base de 0,9892.	Os autores apresentam uma limitação devido aos dados disponíveis publicamente, que muitas vezes são desequilibrados e levam a classes sobre-representadas e baixa sensibilidade a classes sub-representadas.

Tabela 2. Cont.

Autor, Ano	Objetivo do estudo	Amostra	Estratégias de Coleta de	Técnicas	Principais descobertas	Limitações
Vardasca et al., 2018 [36]	Avalie o risco de ulceração com base em imagens térmicas.	56 pacientes em estágio inicial de DFU.	Dados A imagem foi capturada com uma câmera infravermelha sob condições pré-definidas (foi previamente utilizado um período de aclimação de 10 minutos e a sala foi climatizada a uma temperatura de cerca de 22 °C).	K-vizinho mais próximo (KNN)	<ul style="list-style-type: none">Imagens térmicas infravermelhas foram capturadas de 56 pacientes com DFU em estágio inicial, processadas e classificadas usando um método inteligente de mineração de dados (KNN), alcançando uma precisão de 92,5%.Os autores propõem avaliar o desempenho do modelo numa amostra maior.	Os autores não apresentam quaisquer limitações.

Tulloch et al., em 2020 [29], revisaram artigos que abordavam o tema prevenção, diagnóstico e tratamento de DFU utilizando apenas ML. No processo desta revisão, fizemos análise, não nos limitamos a estes artigos que tinham o objetivo de avaliar a capacidade de prever o risco de DFU usando modelos de predição, e sete artigos que abordaram a prevenção baseada em risco de DFU e um modelo de predição, e sete artigos que abordaram a possibilidade de DFU baseada em imagens térmicas.

Os modelos de IA mais utilizados foram SVM ($n=6$) e KNN ($n=5$), seguidos por ANN ($n=4$) e RF ($n=2$) (Figura 2).




Figura 2: Técnicas de predição de inteligência artificial para risco de desenvolvimento de pé diabético.

4. Discussão

As úlceras do pé diabético são complicação que debilitam o pé e que são graves para as pessoas com diabetes. Os profissionais de saúde devem educar os pacientes sobre a prevenção e cuidados com os pés [5]. No entanto, o processo tradicional de diagnóstico de DFUs por médicos e especialistas em DFU é muito caro e demorado - o aprendizado profundo em imagens abre caminhos para o diagnóstico automático de DFU [38]. Desde 1993, dada a natureza complexa das DFUs, as metodologias de IA parecem bem adequadas para abordar aspectos como identificar o risco de úlceras nos pés (ou pior, amputação) com base em tecnologias de sensores apropriadas [39].

Nossa revisão dos artigos descobriu que as DFUs podem ser identificadas de diferentes maneiras. Os classificadores mais utilizados nos artigos revisados são SVM e KNN. Nanda et al. [24] descobriu que o SVM é melhor que os outros algoritmos no ponto MCC, que é 0,875, e F-meas- que é 0,938. O desempenho de KNN e Naive Bayes foi comparável entre si. No estudo, RF foi o mais eficiente em termos de sensibilidade e a SVM foi a mais eficiente em termos de maior especificidade, que foi de 93,8%. Reddy et al. [26] incluiu ELM e RNA na pesquisa, em paralelo ao SVM e ao KNN. O ELM alcançou a mais alta precisão, e RNA na pesquisa, em paralelo ao SVM e KNN. O ELM alcançou o valor mais elevado, seguido pelo SVM com 92,31%. A RNA e a KNN foram comparáveis, ambas com precisão de 84,62%. Em uma revisão da literatura feita por Tulloch et al. [28], todos os modelos alcançaram precisões acima de 90%. SVM e KNN também têm sido usados para previsão de risco pré-baseado na termografia. Em estudo de Cruz-Vega [30], embora o modelo SVM tenha obtido resultados satisfatórios, ele o fez após um procedimento de extração de características, que gostaríamos obteve resultados satisfatórios, o fez após um procedimento de extração de características, que

evitar. Eid et al. [31] descobriram que o KNN alcançou o desempenho mais alto, melhorando a precisão da classificação em 4,3% em comparação ao uso do SVM. Outra técnica eficaz para interpretar os recursos aprendidos das camadas CNN é a incorporação estocástica de vizinhança distribuída em t (t-SNE) [40], que tem sido usada para visualizar grupos de dados de frequência cardíaca em relação aos níveis de glicose. O uso do t-SNE também pode ser generalizado para outras aplicações da CNN, como a detecção de DFU, a fim de analisar qualitativamente os mapas de características extraídos. Além disso, um estudo recente também verificou a consistência dos modelos de redes neurais em relação à dinâmica da glicose e da insulina [41]. Abordagens semelhantes podem ser usadas para analisar o desempenho de DNNs e melhorar ainda mais a interpretabilidade.

As variáveis mais comuns incluídas no modelo prognóstico são idade, tipo de diabetes, índice de massa corporal (IMC) e tipo de diabetes. Nos estudos de Ferreira et al. [23] e Zhang et al. [29], apenas modelos de RNA foram utilizados. No primeiro estudo, relataram sensibilidade de 71%, especificidade de 100% e precisão de 90%. No segundo estudo, relatam que o modelo teve sensibilidade de 92,3% e especificidade de 93,5%.

Muitos autores tentam classificar os termogramas dos pés utilizando análise assimétrica, que consiste em comparar a temperatura do pé com a do pé contralateral [31]. Vários artigos relatam que a termografia é útil para detectar alterações na temperatura da sola que podem aumentar o risco de úlceras por pressão. Cruz-Vega et al. (2020) descobriram que os classificadores CNN requerem uma etapa adicional de aumento de dados para três estruturas (GoogLeNet, AlexNet e DFTNet) [30]. Os maiores valores de sensibilidade, especificidade, AUC (área sob a curva) e acurácia foram obtidos com classificadores como SVM e para as estruturas CNN em quase todos os pares de classes comparados, principalmente nas classes bem separadas. Os melhores resultados do DFNet podem ser atribuídos ao design de rede específico para este tipo de imagens. Embora as estruturas de rede GoogLeNet e AlexNet sejam mais complexas e supostamente melhores classificadores, elas foram treinadas com um tipo diferente de imagens. Este trabalho apresenta uma comparação entre classificadores convencionais como RNA, SVM e classificadores atualmente importantes como CNN [30]. Os trabalhos de Muralidhara et al. [35] utilizam técnicas que permitem apenas a classificação binária de termogramas (o que corresponde ao primeiro caso).

Melhorar os sistemas baseados em IA melhora a precisão e a eficiência do diagnóstico e tratamento em diferentes áreas [43] e, portanto, a segurança dos cuidados [44]. O uso de IA e fontes de dados também reduz a frequência de erros em diferentes áreas do atendimento ao paciente [44].

A principal limitação é a heterogeneidade da pesquisa, pois incluímos diferentes tipos de pesquisas com diferentes modelos de predição. Ao usar conjuntos de dados balanceados com um número significativo de amostras, os modelos de classificação podem alcançar previsões mais precisas. Expandir o conjunto de dados não deve significar apenas incluir informações clínicas mais detalhadas sobre os sujeitos estudados, mas também incluir uma ampla gama das variáveis mais comuns incluídas nos modelos prognósticos. As imagens utilizadas nos estudos analisados geralmente eram obtidas com smartphone ou tablet e não exigiam imagens de alta tecnologia disponíveis apenas em ambientes de pesquisa e industriais. O uso de recursos de imagem artesanais e atributos clínicos brutos no algoritmo de predição facilita uma melhor percepção tanto para médicos quanto para pacientes. Com mais amostras e pesquisas, espera-se que a precisão aumente e que possa ser realizada em unidades especializadas na prática diária para DFU precoce, permitindo atendimento rápido e evitando maiores custos e consequências para o paciente. Diferentes modelos de AI foram aplicados nessas áreas, alcançando melhor desempenho experimental do que os métodos convencionais anteriores de aprendizado de máquina. Por outro lado, vários desafios foram identificados na literatura, incluindo disponibilidade de dados, processamento de características e interpretabilidade de modelos. No futuro, existe um potencial considerável para enfrentar estes desafios através da aplicação de avanços recentes em tecnologias de aprendizagem profunda a dados massivos de tratamento multimodal da diabetes. Esperamos que as tecnologias de aprendizagem profunda sejam amplamente implementadas em ambientes clínicos e melhorem significativamente. Na discussão, comparamos os valores numéricos do desempenho dos modelos relatados nos artigos revisados. Os artigos não utilizaram o mesmo conjunto de dados para treinamento e teste, o que pode ser uma séria limitação em alguns estudos. Também limitamos nossa pesquisa a

Apenas artigos em inglês, deixando aberta a possibilidade de não incluirmos todos os estudos relevantes na revisão.

Contribuições dos Autores: Conceituação, LG e GS; metodologia, LG, ML, AS e GS; análise formal, LG, AS e GS; redação – preparação do rascunho original, LG, ML, AS e GS; redação – revisão e edição, LG e GS; supervisão, LG e GS Todos os autores leram e concordaram com a versão publicada do manuscrito.

Financiamento: Esta pesquisa não recebeu financiamento externo.

Declaração do Conselho de Revisão Institucional: Não aplicável.

Termo de Consentimento Livre e Esclarecido: Não aplicável.

Declaração de disponibilidade de dados: Não aplicável.

Conflitos de interesse: Os autores declaram não haver conflito de interesses.

Referências

1. Organização Mundial da Saúde. Diabetes. Disponível on-line: https://www.who.int/health-topics/diabetes#tab=tab_3 (acessado em 21 novembro de 2022).
2. Negash, Z.; Yismaw, M. Prática de manejo e fatores de risco contribuintes para complicações crônicas entre pacientes adultos com diabetes mellitus tipo 2 em acompanhamento em um hospital universitário terciário. *Diabetes Metab. Syndr. Obes.* **2020**, *13*, 3969. [\[RefCruz\]](#) [\[Pub Med\]](#)
3. Naves, CC O pé diabético: panorama histórico e lacunas no tratamento atual. *Av. Tratamento de feridas* **2016**, *5*, 191–197. [\[RefCruz\]](#) 4. Xie, P.; Li, Y.; Deng, B.; Du, C.; Rui, S.; Deng, W.; Wang, M.; Boey, J.; Armstrong, DG; Poderia.; e outros. Um modelo explicável de aprendizado de máquina para prever a taxa de amputação hospitalar de pacientes com úlcera no pé diabético. *Internacional Ferida J.* **2022**, *19*, 910–918. [\[RefCruz\]](#)
5. Oliver, TI; Mutluoglu, M. Úlcera do pé diabético. *Lancet* **2003**, *361*, 1545–1551.
6. Everett, E.; Mathioudakis, N. Atualização sobre tratamento de úlceras de pé diabético. *Ana. NY Acad. Ciência.* **2018**, *1411*, 153–165. [\[RefCruz\]](#)
7. Armstrong, DG; Boulton, AJ; Bus, SA Úlceras do pé diabético e sua recorrência. *N. Engl. J. Med.* **2017**, *376*, 2367–2375. [\[RefCruz\]](#)
8. Sikhondze, MM; Twesigye, D.; Odongo, CN; Mutibwa, D.; Tayebwa, E.; Tibaijuka, L.; Ayana, SD; Dreque, CC Úlceras do pé diabético: características cirúrgicas, modalidades de tratamento e resultados do tratamento a curto prazo num hospital terciário no sudoeste do Uganda. *Cirurgia de acesso aberto.* **2022**, *15*, 75–87. [\[RefCruz\]](#)
9. Armstrong, DG; Lavery, LA; Harkless, LB Validação de um sistema de classificação de feridas diabéticas: A contribuição da profundidade, infecção e isquemia ao risco de amputação. *Diabetes Care* **1998**, *21*, 855–859. [\[RefCruz\]](#)
10. Oyibo, SO; Judas, EB; Tarawneh, I.; Nguyen, HC; Armstrong, DG; Harkless, LB; Boulton, AJ Os efeitos do tamanho e localização da úlcera, idade do paciente, sexo e tipo e duração do diabetes no resultado das úlceras do pé diabético. *Diabetes. Med.* **2001**, *18*, 133–138. [\[RefCruz\]](#)
11. Boulton, AJ; Vileikyte, L.; Ragnarson-Tennvall, G.; Apelqvist, J. A carga global da doença do pé diabético. *Lanceta* **2005**, *366*, 1719–1724. [\[RefCruz\]](#) [\[Pub Med\]](#)
12. Lim, JZ; Ng, NS; Thomas, C. Prevenção e tratamento de úlceras de pé diabético. *JR Soc. Med.* **2017**, *110*, 104–109. [\[RefCruz\]](#) [\[Pub Med\]](#)
13. Chapel, FM; Crawford, F.; Horne, M.; Leese, GP; Martinho, A.; Weller, D.; Boulton, AJ; Abbott, C.; Monteiro-Soares, M.; Veves, A.; e outros. Desenvolvimento e validação de uma regra de predição clínica para o desenvolvimento de ulceração no pé diabético: uma análise de dados de cinco estudos de coorte. *BMJ Open Diabetes Res. Cuidado* **2021**, *9*, e002150. [\[RefCruz\]](#) [\[Pub Med\]](#)
14. Jovem, M.; Stang, D. Fique elegante: A classificação das úlceras do pé diabético e sua relevância para o tratamento: Parte 1. *Diabet. Pé J.* **2018**, *21*, 52–55.
15. Amisha; Malik, P.; Patânia, M.; Rathaur, VK Visão geral da inteligência artificial na medicina. *J. Fam. Med. Primo. Cuidado* **2019**, *8*, 2328–2331. [\[RefCruz\]](#)
16. Briganti, G.; Le Moine, O. Inteligência artificial na medicina: hoje e amanhã. *Frente. Med.* **2020**, *7*, 27. [\[CrossRef\]](#)
17. Aboul-Ela, MM; Amer, AA; Ismail, SM Previsão de pé diabético usando sistemas híbridos de inteligência artificial. *Internacional J. Adv. Computação. Tecnologia. (IJACT)* **2016**, *5*, 19–29.
18. Howard, T.; Ahluwalia, R.; Papanas, N. O advento da inteligência artificial na medicina do pé diabético: um novo horizonte, uma nova ordem, ou um falso amanhecer? *Internacional J. Baixo. Extremo. Feridas* **2021**, *15347346211041866*. [\[CrossRef\]](#) [\[Pub Med\]](#)
19. Wouter, B.; Schut, MC; Abu-Hanna, A.; van Baal, JG; van Netten, JJ; Bus, SA Desenvolvimento de um modelo de predição de recorrência de úlceras nos pés em pessoas com diabetes utilizando variáveis clínicas de fácil obtenção. *BMJ Open Diabetes Res. Cuidado* **2021**, *9*, e002257.
20. Hernández-Contreras, D.; Peregrina-Barreto, H.; Rangel-Magdaleno, J.; Gonzalez-Bernal, J. Revisão narrativa: Pé diabético e termografia infravermelha. *Física infravermelha. Tecnologia.* **2016**, *1*, 105–117. [\[RefCruz\]](#)

21. Hong, QN; Pluye, P.; Bujold, M.; Wassef, M. Projetos de síntese convergente e sequencial: Implicações para conduzir e relatar revisões sistemáticas de evidências qualitativas e quantitativas. *Sist. Rev.* **2017**, 6, 1–4. [\[RefCruz\]](#)
22. Polit, D.; Beck, CT *Enfermagem Pesquisa Gerando e Avaliando Evidências para a Prática de Enfermagem*, 11ª ed.; Wolters Kluwer: Alphen, O Holanda, 2021.
23. Ferreira, AC; Ferreira, DD; Oliveira, HC; de Resende, IC; Anjos, A.; de Moraes Lopes, MH Método competitivo baseado em camadas neurais para identificar pessoas com alto risco de pé diabético. *Computação. Biol. Med.* **2020**, 120, 103744. [\[CrossRef\]](#)
24. Nanda, R.; Nath, A.; Patel, S.; Mohapatra, E. Algoritmo de aprendizado de máquina para avaliar fatores de risco de úlceras de pé diabético e seus gravidade. *Med. Biol. Eng. Computação.* **2022**, 60, 2349–2357. [\[RefCruz\]](#)
25. Ohura, N.; Mitsuno, R.; Sakisaka, M.; Terabe, Y.; Morishige, Y.; Uchiyama, A.; Okoshi, T.; Shinji, I.; Takushima, A. Redes neurais convolucionais para detecção de feridas: O papel da inteligência artificial no tratamento de feridas. *J. Tratamento de feridas* **2019**, 28, S13–S24. [\[RefCruz\]](#)
26. Reddy, SS; Mahesh, G.; Preethi, NM Explorando algoritmos de aprendizado de máquina para diagnosticar úlceras nos pés em pacientes diabéticos. *Transação endossada pela EAI . Tecnologia Pervasiva de Saúde.* **2021**, 7, e2. [\[RefCruz\]](#)
27. Schäfer, Z.; Mathisen, A.; Svendsen, K.; Engberg, S.; Rolighed Thomsen, T.; Kirketerp-Møller, K. Rumo ao apoio à decisão baseado em aprendizado de máquina no tratamento do diabetes: Um estudo de estratificação de risco em úlcera e amputação do pé diabético. *Frete. Med.* **2021**, 7, 601602. [\[RefCruz\]](#) [\[Pub Med\]](#)
28. Tulloch, J.; Zamani, R.; Akrami, M. Aprendizado de máquina na prevenção, diagnóstico e tratamento de úlceras de pé diabético: A revisão sistemática. *Acesso IEEE* **2020**, 8, 198977-9000. [\[RefCruz\]](#)
29. Zhang, D.; Dong, W.; Guan, H.; Yakupu, A.; Wang, H.; Chen, L.; Lu, S.; Tang, J. Previsão de resultados baseada em angiografia por CT em pacientes com úlcera no pé diabético: uma abordagem de aprendizagem estatística. *Diagnóstico* **2022**, 12, 1076. [\[CrossRef\]](#)
30. Cruz-Vega, I.; Hernández-Contreras, D.; Peregrina-Barreto, H.; Rangel-Magdaleno, JD; Ramirez-Cortes, JM Aprendizado profundo classificação para termogramas do pé diabético. *Sensores* **2020**, 2, 1762. [\[CrossRef\]](#)
31. Eid, M.M.; Yousef, RN; Mohamed, MA Um sistema automatizado proposto para classificar o pé diabético por termografia. *Internacional J. Ciência. Eng. Res.* **2018**, 9, 371–381.
32. Filipe, V.; Teixeira, P.; Teixeira, A. Classificação automática de termogramas de pés utilizando técnicas de aprendizagem automática. *Algoritmos* **2022**, 15, 236. [\[CrossRef\]](#)
33. Goyal, M.; Reeves, ND; Davison, AK; Rajbhandari, S.; Spragg, J.; Yap, MH Dfunet: Redes neurais convolucionais para diabéticos classificação de úlcera no pé. *IEEE Trans. Emergir. Principal. Computação. Intel.* **2018**, 4, 728–739. [\[RefCruz\]](#)
34. Gururajão, SB; Venkatappa, U.; Shivaram, JM; Sikkandar, MEU; Al Amoudi, A. Termografia infravermelha e computação suave para avaliação do pé diabético. Em *Aprendizado de Máquina em Análise de Bio-Sinais e Diagnóstico por Imagem*; Academic Press: Cambridge, MA, EUA, 2019; pp. 73–97.
35. Muralidhara, S.; Lucieri, A.; Dengel, A.; Ahmed, S. Classificação holística multiclasse e classificação de ulcerações do pé diabético de imagens térmicas plantares usando aprendizagem profunda. *Informações de saúde Ciência. Sist.* **2022**, 10, 1–9.
36. Vardasca, R.; Vaz, L.; Magalhães, C.; Seixas, A.; Mendes, J. Rumo à classificação das úlceras do pé diabético com imagens térmicas infravermelhas. Em *Anais da 14ª Conferência Quantitativa de Termografia Infravermelha*, Berlim, Alemanha, 25–29 de junho de 2018.
37. Rafiq, MK; Kamran, H.; Ayub, A.; Jameel, F. Úlceras do pé diabético: percepções sobre manejo e prevenção. *Pacote. J. Med. Ciências da Saúde .* **2022**, 16, 633. [\[CrossRef\]](#)
38. Das, SK; Roy, P.; Mishra, AK Efficientenet-b0 pré-treinado com otimizador ajustado, taxa de aprendizagem e tamanho de imagem para melhorar o diagnóstico de úlceras no pé diabético. Em *Eletrônica e Automação Emergentes*; Springer: Singapura, 2022; págs.
39. Chemello, G.; Salvatori, B.; Morettini, M.; Tura, A. Metodologias de inteligência artificial aplicadas a tecnologias de rastreamento, diagnóstico e cuidado do pé diabético: Uma revisão narrativa. *Biossensores* **2022**, 12, 985. [\[CrossRef\]](#)
40. Maaten, L.; Hinton, G. Visualizando dados usando t-SNE. *J. Mach. Aprender. Res.* **2008**, 9, 2579–2605.
41. Kushner, T.; Sankaranarayanan, S.; Breton, M. Verificação de conformidade para modelos de redes neurais da dinâmica glicose-insulina. Em *Anais da 23ª Conferência Internacional sobre Sistemas Híbridos: Computação e Controle*, Sydney, Austrália, 21–24 de abril de 2020; páginas 1–12.
42. Zhu, T.; Li, K.; Herrero, P.; Georgiou, P. Aprendizado profundo para diabetes: uma revisão sistemática. *J. Biomédica. Informação de Saúde.* **2020**, 25, 2168–2194. [\[RefCruz\]](#) [\[Pub Med\]](#)
43. Ahuja, AS O impacto da inteligência artificial na medicina no futuro papel do médico. *PeerJ* **2019**, 7, e7702. [\[RefCruz\]](#) [\[Pub Med\]](#)
44. Bates, DW; Levine, D.; Syrowatka, A.; Kuznetsova, M.; Craig, KJ; Rui, A.; Jackson, GP; Rhee, K. O potencial do artificial inteligência para melhorar a segurança do paciente: uma revisão do escopo. *Dígito NPJ. Med.* **2021**, 4, 1–8. [\[RefCruz\]](#)

Isonção de responsabilidade/Nota do editor: As declarações, opiniões e dados contidos em todas as publicações são exclusivamente de responsabilidade do (s) autor(es) e colaborador(es) individual(is) e não do MDPI e/ou do(s) editor(es). O MDPI e/ou o(s) editor(es) isentam-se de responsabilidade por qualquer dano a pessoas ou propriedades resultante de quaisquer ideias, métodos, instruções ou produtos mencionados no conteúdo.