

Aprendizado de Máquinas Aplicado ao Diagnóstico por Imagem: Uma Revisão Integrativa

Machine Learning Applied to Medical Imaging and Diagnostics: An Integrative Review

Fábio Giancoli Jabour¹, Rafael Matoso de Oliveira Figueiredo¹, Carlos Alberto Mourao-Junior^{1*}

RESUMO

As tecnologias de Inteligência Artificial tiveram um avanço proeminente nos últimos anos que, por consequência, acompanha sua crescente aplicação na assistência em saúde. O destaque, nesse contexto, é o uso de Aprendizado de Máquinas no diagnóstico por imagem, que, combina a capacidade de treinamento do desempenho do algoritmo, com o uso de grandes bases de dados de imagens médicas. Esse artigo tem o objetivo de apresentar conceitos sobre o tema, com explicações acessíveis sobre os fundamentos do aprendizado de máquinas, e de como é sua usabilidade em exames de imagem. Ainda, expor o estado da arte atual e levantar discussões relevantes sobre obstáculos, vantagens e desvantagens desta ferramenta para a prática médica, assistência e sistemas de saúde.

Palavras-chave: Aprendizado de Máquina; Inteligência Artificial; Diagnóstico Por Imagem

ABSTRACT

Artificial Intelligence technologies advanced greatly in recent years, which is accompanied by its growing application in health care. In this sense, the highlight is the use of Machine Learning on medical imaging and diagnostics, due to the combination of the capability to improve the algorithm performance with training, and the vast medical imaging databases. This article aims to introduce concepts on this topic, with accessible explanations about Machine Learning and how it is used in medical imaging and diagnostics. Moreover, to address the state of the art and raise relevant discussions about obstacles, advantages and disadvantages of this tool for medical practice, health care and health systems.

Keywords: Machine Learning; Artificial Intelligence; Imaging; Diagnostics

¹ Universidade Federal de Juiz de Fora

*E-mail: camouraojr@gmail.com

INTRODUÇÃO

O Aprendizado de Máquinas (AM) e a Inteligência Artificial (IA) são áreas em franco desenvolvimento nos últimos anos e com crescentes campos de aplicação. Na área médica, mais especificamente no diagnóstico por imagens, são tecnologias com o potencial de transformar a assistência em saúde.

A aplicação dessas técnicas pode auxiliar em corrigir desafios prevalentes nos sistemas de saúde. É estimado que quase todo paciente passará por um erro diagnóstico durante a vida, e pelas implicações que esse erro envolve (MCGLYNN et al., 2015). O uso de IA pode ainda otimizar o uso de recursos, o tempo e a qualidade do contato entre médicos e pacientes e, ainda, possivelmente, impactar na saúde de longo prazo da população (TOPOL et al., 2019).

O interesse e os investimentos no setor também crescem rapidamente. Em uma avaliação e projeção do crescimento da IA no mercado de saúde, se estima que o crescimento vá de 6,9 bilhões de dólares, em 2021, para 67,4 bilhões em 2027. Ainda se projeta, que a área de diagnósticos e imagem seja a com a maior taxa de crescimento anual composto, o que é atribuído à quantidade de dados disponíveis e o crescente número de *startups* nesse setor (REPORT LINKER, 2021)

O aprendizado de máquinas consiste na capacidade do sistema em adquirir habilidades de maneira autônoma ao extrair padrões de grandes bancos de dados, conhecidos como *big data*. Na área da saúde, a quantidade de dados criados pode contribuir ainda mais com a acurácia de ferramentas que usam AM, um exemplo são os 2 bilhões de radiografias de tórax realizadas por ano (TOPOL et al., 2019). Assim, o crescimento do poder computacional e a informatização de processos, como bancos a partir de prontuários eletrônicos e sistemas de exames de imagem podem alimentar as bases de dados de imagens médicas.

Dessa forma, o uso do aprendizado de máquinas, pode aprimorar o diagnóstico de imagem, de forma ampla, por meio da identificação de padrões ocultos e complexos, facilitando e acelerando diagnóstico e a tomada de decisões clínicas (MARTIN-ISLA et al., 2020). Futuramente, com uma evolução ainda maior da capacidade de computação de dados, o aprendizado de máquina poderá extrair ainda mais recursos dos dados, superando, talvez, o que o ser humano é capaz de fazer (CHOY et al., 2018).

Esse artigo tem o objetivo de apresentar conceitos sobre o tema, com explicações acessíveis sobre os fundamentos tanto do aprendizado de máquinas, em si, quanto para a aplicação do método em exames de imagem. Ainda, expor o estado da arte atual e levantar discussões relevantes sobre obstáculos, vantagens e desvantagens dessa ferramenta para a prática médica, assistência e sistemas de saúde.

METODOLOGIA

O presente estudo trata-se de uma revisão integrativa de artigos científicos, ou seja, utilizando uma abordagem metodológica que permite a combinação de diversos métodos com estudos experimentais e não experimentais, o que possibilita uma compreensão mais completa do tema analisado e fornecendo suporte para tomada de decisões e melhores resultados na prática clínica (WHITTEMORE, 2005).

A busca foi realizada levando em consideração as publicações realizadas em um recorte temporal de 2002 a 2022, nas bases de dados Bireme (Biblioteca Virtual em Saúde), Pubmed, Scielo, Science Direct, Lilacs e Cochrane. Os critérios de inclusão foram os seguintes: a língua de origem dos artigos (portuguesa, inglesa e espanhola) e apresentarem o tema pertinente a esta revisão. Todos os desenhos de estudo em concordância com os critérios de inclusão foram admitidos. Os critérios de não inclusão e de exclusão foram os artigos considerados, em virtude de algum viés metodológico, não adequados para a presente revisão, já que a revisão integrativa permite esse grau de liberdade aos autores, qual seja, eleger o referencial bibliográfico que considerar mais adequados para seus fins.

O objetivo foi sintetizar os achados da literatura disponível, e, ainda, levantar uma discussão sobre o tema, com tópicos relevantes para a área da saúde. Devido à natureza do estudo de revisão, não foi necessária a aprovação pelo Comitê de Ética em Pesquisa.

INTELIGÊNCIA ARTIFICIAL E APRENDIZADO DE MÁQUINAS

Inteligência é a capacidade de adquirir conhecimento através de aprendizado e aplicá-lo para solucionar problemas. Sendo assim, Inteligência Artificial, ou IA, é classificado como a utilização de um programa ou um algoritmo para solucionar problemas que exijam, do ser humano, o uso de inteligência.

Já o Aprendizado de Máquinas, ou AM, pode ser classificado como qualquer IA programada para seguir um algoritmo que permita uma melhora na sua performance baseado na análise de novos dados.

A capacidade das IAs de processar enormes quantidades de dados aliado à capacidade dos algoritmos de AM de aprender a partir de exemplos, ou seja, dados, tornou possível a criação de programas que realizam tarefas complexas como jogar xadrez ou dirigir um carro. Essas habilidades aprendidas seriam quase impossíveis de serem programadas, uma vez que cada decisão que a máquina deve fazer depende de uma grande quantidade de variáveis (LUDERMIR, 2021).

O AM pode ser classificado de acordo com o método de aprendizado, podendo ser um algoritmo de aprendizado por reforço, supervisionado ou não supervisionado. O primeiro tipo é baseado em um sistema de recompensa para levar a máquina ao melhor comportamento no contexto desejado. No segundo, a máquina aprende a tomada de decisões a partir de uma base de dados pré-rotulada, denominada conjunto de treinamento. E no último tipo, no entanto, não é necessário pré-rotular os dados, sendo a máquina capaz de obter as análises a partir de agrupamentos baseados em semelhanças dos dados, o que permite a detecção de padrões antes desconhecidos (SENDERS et al., 2018)

Além da forma de aprendizado existem ainda os tipos de algoritmos, como por exemplo, *Random Forest*, *Nearest Neighbor* e *Deep Learning*, que têm suas maneiras específicas de analisar e compilar os dados para chegar ao programa final, sendo assim existem programas mais específicos para cada tipo de dado a ser analisado ou para o resultado final desejado.

Hoje em dia um dos algoritmos que mais tem sido utilizado é o *Deep Learning*, ou aprendizado profundo, no qual a máquina tenta através da utilização de diversas camadas de processamento extrair dados e atributos do banco de dados que lhe foi fornecida, sendo assim esse algoritmo minimiza a necessidade de pré-processamento e rotulação dos dados (SANTOS et al., 2019).

Apesar da grande capacidade dos computadores atuais, a falta de esclarecimento de como os algoritmos de AM chegam às suas conclusões, todas as inferências e

correlações criadas por eles serão submetidas à mesma avaliação de performance que qualquer outra teoria criada pelo homem. Sendo assim os programas de AM são avaliados de acordo com o cálculo de acurácia, sensibilidade, especificidade e área sob a curva ROC. Através desses mesmos testes de acurácia foi constatado o caráter sinérgico entre predições híbridas máquina-humano, fazendo com que essas sejam mais acuradas do que predições feitas por humanos e AM sozinhos (PEREIRA et al., 2019).

No entanto, apesar do grande avanço que está sendo proporcionado por esses novos tipos de tecnologias, ainda existem algumas limitações para seu desenvolvimento e utilização. Um dos principais entraves atuais do AM está no seu comportamento de caixa preta, que dificulta a compreensão de como ou porque um algoritmo chegou a determinado resultado.

Outro grande problema dos AM são os vieses que ocorrem devido aos vieses presentes nos bancos de dados utilizados durante seu desenvolvimento, assim como os vieses gerados durante a supervisão humana para pré-processar e rotular os dados. Esses vieses devem ser eliminados durante as fases de desenvolvimento dos AM, para reduzir o risco de falha e erros de predição, para isso, portanto, deve-se reavaliar a responsabilidade dos indivíduos e organizações que estão desenvolvendo esses algoritmos ou que estão selecionando os bancos de dados que serão usados para sua criação a fim de minimizar os efeitos dos vieses nos algoritmos, visando criar AM que sejam confiáveis, compreensíveis e que preservem a integridade do paciente (TOH et al., 2019).

PROCESSAMENTO DE IMAGENS MÉDICAS

Os exames de imagem devem ser transformados em dados para passar pelo processo de análise, realizado por AM. A imagem passa por processos de visão por computador para detecção, segmentação e classificação. Como exemplo, pode-se detectar uma imagem de um tumor, como um melanoma, segmentar para separar estruturas anatômicas adjacentes e classificar de acordo com critérios diagnósticos, o que pode, nesse caso, afastar diagnósticos diferenciais de acordo com a imagem (NICHOLS et al., 2019).

Para que isso aconteça, deve haver um entendimento que a imagem consiste em um aglomerado de pixels que são distribuídos espacialmente e em uma escala de cinza. Nesse sentido, podemos formar uma função $f(x,y)$, em que haverá coordenadas para cada pixel e valores atribuídos dentro da escala de cinza. Para imagens com profundidade, como a Tomografia Computadorizada e a Ressonância Magnética, o atributo da altura da espessura do corte será adicionado aos dados, dessa forma, cada ponto da imagem representa um voxel (MAHESH, 2013). A partir dessas bases, temos as etapas e abordagens para o processamento das imagens.

A Segmentação é a etapa de dividir a imagem do exame em partes que tenham correlação com a anatomia normal ou a anatomia patológica, e, assim, separar tecidos e estruturas. Isso é baseado na propriedade dos níveis de cinza, na existência de bordas ou na similaridade, o que seria identificado pelo algoritmo (GONZALES et al., 2007).

Extração de atributos consiste em captar os valores de características visuais reconhecidas pelos algoritmos: texturas, formas, contorno, cor, estimativas de área e de volume. Dessa forma, são criados histogramas, que representam a distribuição na escala de níveis de cinza. Entretanto, para entendimento da distribuição espacial do conteúdo da imagem deve se usar a textura, que será essencial para identificação da lesão a ser estudada. Com os atributos captados, há uma seleção do que é relevante para uma determinada análise e os dados que apresentam redundância (GONZALES et al., 2007. SANTOS et al., 2019).

Por fim, esses dados extraídos são utilizados pelo algoritmo, que, por meio do Aprendizado de Máquinas, usa as características para comparar entre as imagens contidas no banco de dados, para que ocorra a interpretação e, conseqüentemente, o diagnóstico.

ESTADO DA ARTE

A grande relevância desse tema, associado ao imenso potencial do AM tem estimulado diversos estudos sobre a eficácia e aplicabilidade de tais ferramentas na prática médica, nos mais diferentes campos.

Uma das primeiras áreas a incorporar tais tecnologias foi a dermatologia, que continua ainda hoje a experimentar novas utilidades para o AM, como na utilização de um algoritmo de deep learning para realizar diagnósticos comuns em dermatopatologia, demonstrando que tais ferramentas têm capacidade de aprimorar e agilizar o diagnóstico

dermatológico (OLSEN et al., 2018). Outra aplicabilidade de IAs no âmbito da dermatologia é detecção de melanomas através de um dermatoscópio, que comparando um profissional treinado, um profissional não treinado e uma AM, demonstrou que tanto a análise do profissional treinado quanto a do AM são superiores a do profissional sem treinamento, revelando a relevância desse tipo de ferramenta, principalmente em centros com a ausência de profissionais treinados (PICCOLO et al., 2002).

A grande aplicabilidade do AM faz com que, então, ele seja aplicado em outras diversas áreas, além da dermatologia, como no para realizar diagnóstico precoce de doenças mamárias usando imagens térmicas (RESMINI et al, 2012). Ou, ainda, para auxiliar na classificação de sacroiliite inflamatória ativa ao exame de ressonância magnética (FALEIROS et al., 2020).

Na cardiologia, programas de *Deep Learning* foram usados para classificação de ecocardiogramas, com desempenho superior a ecocardiografistas (MANDANI et al., 2018), e foram capazes de avaliar cardiomiopatia hipertrófica e hipertensão pulmonar, por exemplo (ZHANG et al., 2018).

Em exames oftalmológicos, essas tecnologias podem diagnosticar retinopatias diabéticas, degeneração macular relacionada à idade, glaucoma, cegueira infantil, entre outras patologias (GULSHAN et al., 2016. RAUMBIBOONSUK et al., 2019. ABRÀMOFF et al., 2016. TING et al., 2017. YIM et al., 2020. LI et al., 2018. BROWN et al., 2018). No exame feito por otorrinolaringologistas, podem auxiliar por meio de dispositivos usados com smartphones (LIVINGSTONE et al., 2019).

Programas de IA ainda se mostraram eficientes em exames endoscópicos, para melhor visualização de lesões, detecção de lesões que possam passar despercebidas pelo endoscopista e, ainda, diagnosticar lesões (EL HAJJAR et al., 2020). Podem ser usados em câncer gástrico, esofágico e na detecção de H. Pylori (KUBOTA et al., 2020. HORIE et al., 2019. ITOH et al., 2018).

AVALIAÇÃO DO DIAGNÓSTICO AUXILIADO POR APRENDIZADO DE MÁQUINAS

O alto interesse financeiro, aliado à velocidade avassaladora dos avanços tecnológicos na área, pode colocar em risco a implementação do AM ao diagnóstico por

imagens. Dessa forma, deve sempre se partir do princípio de benefício clínico para os pacientes, e na formação de evidências sólidas.

Assim, estudos de qualidade devem ser o foco nessa área, com rigor metodológico, avaliando não só a acurácia, mas também o impacto na história natural da doença. Para tal, devemos avaliar a abordagem científica, tanto na sua metodologia, quanto no benefício a longo prazo na assistência médica.

Comparação com médicos treinados

Uma possibilidade para testar um método é comparar a acurácia do diagnóstico auxiliado por computador com profissionais da saúde. Uma revisão de 2020 avaliou estudos que utilizam esse método e só encontraram 10 registros de ensaios clínicos randomizados, com somente dois já publicados. Além disso, encontraram 81 ensaios clínicos não randomizados, e 58 deles foram classificados como de alto risco para viés (NAGENDRAN et al., 2020). Ainda, um problema encontrado nesses estudos é que poucos usam a mesma amostra de exames, para comparar os grupos de profissionais de saúde e os de algoritmos de diagnóstico (LIU et al., 2019).

Evolução da doença

Outro método comparativo é com a própria evolução da doença. Nessa modalidade seriam feitos estudos longitudinais de longo prazo, com o objetivo de esperar a confirmação do diagnóstico conforme a evolução da doença. Isso permite avaliar critérios clínicos como sintomas mais característicos que aparecem mais tardiamente. Ainda, é necessário alto rigor metodológico.

Comparação com outros métodos de diagnóstico

A comparação, dependendo da patologia a ser estudada, pode ser feita com outros métodos diagnósticos já consolidados na medicina. Dessa forma, se compara o AM aplicado ao diagnóstico em uma imagem, com outra modalidade, como, por exemplo, uma biópsia. Esse método se faz interessante se existe um método padrão-ouro, com uma acurácia muito elevada, para que a comparação seja efetiva.

Impacto clínico

A partir de estudos mais robustos sobre a usabilidade desses métodos, deve-se partir para o entendimento dos benefícios a longo prazo. Dessa maneira, a interação do diagnóstico feito com o auxílio de Aprendizado de Máquinas, se expande para toda a cadeia de assistência à saúde, à medida que, a partir do diagnóstico, ou ausência dele, serão tomadas decisões clínicas e medidas de assistência, como planos terapêuticos, exames complementares, consultas e estratégias de prevenção.

O diagnóstico pode promover intervenções desnecessárias e aumentar iatrogenias, ou, ainda, levar a tratamentos que não sejam suficientemente eficazes. Essas situações têm impacto direto na história de vida do paciente, alterando drasticamente sua relação com a doença e sua qualidade de vida.

Em última análise, deve ser avaliado como o diagnóstico, mesmo que mais acurado, irá influenciar na saúde global do paciente naquele contexto. O que demanda estudos bem conduzidos, reavaliação de protocolos, de diretrizes e de políticas públicas.

IMPACTOS NA PRÁTICA MÉDICA

O AM tem a capacidade de ser implementado em diversas áreas da medicina, hoje em dia os campos que mais o utilizam são a dermatologia e, mais recentemente, a radiologia. Esse novo passo, na história da radiologia com o auxílio do AM, levanta algumas incertezas sobre como essa relação está sendo organizada e qual o impacto que ela irá gerar na área, tanto em relação à qualidade do diagnóstico, quanto em relação à necessidade de radiologistas.

No que tange a existência ou não do radiologista, a pequena gama de AM em uso hoje na área e a dificuldade e complexidade na criação e treinamento de novos modelos de AM, a substituição do médico radiologista por máquinas ainda é um futuro distante. No entanto, ainda assim é necessário que os novos radiologistas tenham mais conhecimento sobre essa tecnologia para que estejam preparados para supervisionar o seu funcionamento e interpretar seus resultados (KOHLI et al., 2017).

Sendo assim, essa nova tecnologia dificilmente veio para substituir, mas sim para ser mais uma ferramenta a ser usada pelo médico para facilitar a tomada de decisões e a análise de dados. Essa combinação tem a capacidade de aprimorar a qualidade do sistema de saúde, assim como melhorar a eficácia e eficiência do diagnóstico por imagem e do fluxo de trabalho dos radiologistas, além de reduzir a ocorrência de eventos adversos ou

erros no diagnóstico (CHOY et al., 2018). Uma das utilidades dessas ferramentas seria a de filtrar do grande número de exames os que se apresentam normais e destacar os que tiverem algum tipo de anormalidade, para que o radiologista possa focar seu trabalho no diagnóstico (WONG et al., 2019).

Outro grande impacto que essas tecnologias podem proporcionar para a medicina é a possibilidade de promover cuidado individualizado e direcionado, a chamada medicina de precisão, que leva em conta diversos dados do paciente, como genética, ambiente, fatores de risco e estilo de vida, permitindo assim um cuidado mais completo e específico para o paciente. Isso só é possível graças à grande capacidade do AM extrair informação de big data e produzir resultados que podem ser utilizados na predição e análise clínica individual (CHOY et al., 2018).

Apesar de fornecer dados e indicar qual a melhor decisão a ser tomada, é importante salientar que esse tipo de tecnologia está se desenvolvendo para atuar como uma ferramenta no diagnóstico e não como autor final da decisão. Sendo assim, em caso de erro médico, o criador do algoritmo não poderá ser o culpado, mas sim o médico que está tomando as decisões. Ou seja, apesar de indicar as melhores decisões, as escolhas feitas pelo AM devem ser revisadas pelo profissional da saúde, que irá decidir ou não utilizar a informação fornecida (CHOY et al., 2018).

Apesar de muitos autores indicarem que essas tecnologias não vieram para causar disrupção na profissão do radiologista, mas sim agregar valor, alguns ainda se mantêm céticos quanto à capacidade do ser humano de competir com a eficiência e eficácia do AM, questionando em alguns casos se a profissão irá se perpetuar durante os próximos ou anos ou se estará fadada à extinção. Essa grande capacidade do AM e a grande expectativa criada ao seu redor faz com que profissões que exerçam reconhecimento de padrões como radiologistas e patologistas sejam cada vez mais substituídas por essa nova tecnologia (CHOCKLEY et al., 2016).

No entanto esse mesmo questionamento já foi levantado outras vezes, em relação a outras novas tecnologias, como no advento da ressonância magnética ou da tomografia computadorizada, e sendo assim a utilização do AM no dia a dia da radiologia apesar de modificar o fluxo de trabalho, apenas com o tempo será possível observar se essa tecnologia irá implicar em um profissional mais especializado e focado no diagnóstico mais específico ou se cada vez mais ele será menos requerido (WONG et al., 2019).

CONCLUSÃO

A aplicação do AM ao diagnóstico por imagem, assim como todas as inovações médicas, passa por discussões bioéticas fundamentais, já que, o impacto maior recai sobre vidas humanas. Nesse sentido, os algoritmos tendem a magnificar as informações contidas nos dados, o que inclui vieses e preconceitos. Condições socioeconômicas ruins, por exemplo, podem ser reforçadas pela IA, perpetuando a falta de acesso a produtos de saúde, como exames de imagem mais caros ou medicamentos. O algoritmo, assim, pode ser levado a tomada de decisões antiéticas, em busca do que seria considerado o melhor desfecho (KOHLI et al., 2017).

Os dados que serão magnificados e como o tratamento desses dados é feito no processo de Aprendizado de Máquina são os pontos centrais. Deve-se assegurar que os dados do paciente sejam utilizados de maneira segura, mantendo a privacidade do paciente e assegurando sigilo sobre os seus dados (KOHLI et al., 2017). Além de uma constante revisão de resultados, eficiência e processos, prezando o benefício clínico para o paciente, a não-maleficência e entendendo as especificidades da tecnologia, como o comportamento de caixa preta.

A avaliação dos algoritmos deve partir dos princípios, então, da área da saúde, indo além de apenas a acurácia, para priorizar o impacto clínico, o bem-estar e a qualidade dos serviços e sistemas de saúde. Nesse âmbito, são relevantes estudos de qualidade, constante avaliação e revisão dos resultados, além da orientação consciente para seu uso na prática. Essas decisões passam por obstáculos, visto o crescimento muito acentuado do mercado e, por conseguinte, possíveis conflitos de interesse.

O impacto na qualidade da assistência em saúde se faz muito relevante no potencial do diagnóstico em desencadear outras decisões clínicas. Sobretudo, o cuidado deve ser com o aumento maciço no número de diagnósticos, que podem causar o aumento de iatrogenias e intervenções sem a capacidade de mudar a história natural da doença.

Portanto, essas transformações têm a capacidade de impactar o atual modelo dos sistemas e serviços de saúde. Deve ser entendido como serão aplicados de forma ampla, o acesso pode ser restrito, por conta de custos, o que irá aumentar desigualdades. Ou ainda, podem ser aplicados de forma a desonerar os sistemas, com a automatização dos

processos, o que pode reduzir tempos de espera, desigualdades sociogeográficas, carga de trabalho de profissionais da saúde e foco de recursos em exames complementares.

Por fim, o uso do Aprendizado de Máquinas pode alavancar a medicina de precisão, transformando a assistência em um cuidado mais individualizado para cada paciente. Essa inovação surge a partir do aumento exponencial da quantidade de dados do paciente passível de análise, sendo assim, usados, não somente para o diagnóstico, mas para decisões terapêuticas e prognóstico. Essa revolução pode representar, também, uma mudança de paradigma na prática médica, com maior tempo disponível para o lado humano da medicina, transformando a relação médico-paciente, sem, contudo, se propor a tirar do médico a incumbência de tomar suas decisões clínicas, porquanto essas decisões dependem de um tripé: busca do melhor ferramental (evidências científicas, tecnologia [IA, AM] etc.), experiência do médico e idiosincrasias do paciente. Enfim, a tecnologia deve vir para auxiliar (agregar valor), sem a pretensão de substituir.

REFERÊNCIAS

- ABRÀMOFF, M. D.; LOU, Y.; ERGINAY, A.; CLARIDA, W.; AMELON, R.; FOLK, J.C.; NIEMEIJER, M. Improved Automated Detection of Diabetic Retinopathy on a Publicly Available Dataset Through Integration of Deep Learning. **Investigative Ophthalmology & Visual Science**, v. 57, n. 13, p. 5200-5206, 2016.
- BROWN, J.M.; CAMPBELL, J.P.; BEERS, A.; CHANG, K.; OSTMO, S.; CHAN, R.V.P.; DY, J.; ERDOGMUS, D.; IOANNIDIS, S.; KALPATHY-CRAMER, J.; CHIANG, M.F. BROWN, J. M. Automated Diagnosis of Plus Disease in Retinopathy of Prematurity Using Deep Convolutional Neural Networks. **JAMA Ophthalmology**, v. 136, n. 7, p. 803, 2018.
- CHOCKLEY, K.; EMANUEL, E. The End of Radiology? Three Threats to the Future Practice of Radiology. **Journal of the American College of Radiology**, v. 13, n. 12, p. 1415–1420, 2016.
- CHOY, G.; KHALILZADEH, O.; MICHALSKI, M.; DO, S.; SAMIR, A.E.; PIANYKH, O.S.; GEIS, J.R.; PANDHARIPANDE, P.V.; BRINK J.A.; DREYER, K.J. Current Applications and Future Impact of Machine Learning in Radiology. **Radiology**, v. 288, n. 2, p. 318–328, 2018.
- EL HAJJAR, A.; REY, J.-F. Artificial intelligence in gastrointestinal endoscopy. **Chinese Medical Journal**, v. 133, n. 3, p. 326–334, 2020.
- FALEIROS, M.C.; NOGUEIRA-BARBOSA, M.H.; DALTO, V.F.; FERREIRA JÚNIOR, J.R.; TENÓRIO, A.P.M.; LUPPINO-ASSAD, R.; AZEVEDO-MARQUES, P.M.D. Machine learning techniques for computer-aided classification of active inflammatory sacroiliitis in magnetic resonance imaging. **Advances in Rheumatology**, v. 60, n. 1, 2020.
- GONZALEZ, R.C.; WOODS, R.E. **Digital image processing**. Upper Saddle River, NJ: Prentice Hall, 2007.
- GULSHAN, V.; PENG, L.; CORAM, M.; STUMPE, M.C.; WU, D.; NARAYANASWAMY, A.; VENUGOPALAN, S.; WIDNER, K.; MADAMS, T.; CUADROS, J.; KIM, R.; RAMAN, R.; NELSON, P.C.; MEGA, J.L.; WEBSTER, D.R. Development and Validation of a Deep Learning Algorithm for Detection of Diabetic Retinopathy in Retinal Fundus Photographs. **JAMA**, v. 316, n. 22, p. 2402-2410, 2016.
- HORIE, Y.; YOSHIO, T.; AOYAMA, K.; YOSHIMIZU, S.; HORIUCHI, Y.; ISHIYAMA, A.; HIRASAWA, T.; TSUCHIDA, T.; OZAWA, T.; ISHIHARA, S.; KUMAGAI, Y.; FUJISHIRO, M.; MAETANI, I.; FUJISAKI, J.; TADA, T. Diagnostic outcomes of esophageal cancer by artificial intelligence using convolutional neural networks. **Gastrointestinal Endoscopy**, v. 89, n. 1, p. 25–32, 2019.
- ITOH, T.; KAWAHIRA, H.; NAKASHIMA, H.; YATA, N. Deep learning analyzes *Helicobacter pylori* infection by upper gastrointestinal endoscopy images. **Endoscopy International Open**, v. 06, n. 02, p. E139–E144, 2018.

KOHLI, M.; PREVEDELLO, L.M.; FILICE, R.W.; GEIS, J.R. Implementing Machine Learning in Radiology Practice and Research. **American Journal of Roentgenology**, v. 208, n. 4, p. 754–760, 2017.

KUBOTA, K.; KURODA, J.; YOSHIDA, M.; OHTA, K.; KITAJIMA, M. Medical image analysis: computer-aided diagnosis of gastric cancer invasion on endoscopic images. **Surgical Endoscopy**, v. 26, n. 5, p. 1485–1489, 2011.

LI, Z.; HE, Y.; KEEL, S.; MENG, W.; CHANG, R.T.; HE, M. Efficacy of a Deep Learning System for Detecting Glaucomatous Optic Neuropathy Based on Color Fundus Photographs. **Ophthalmology**, v. 125, n. 8, p. 1199–1206, 2018.

LIU, X.; FAES, L.; KALE, A.U.; WAGNER, S.K.; FU, D.J.; BRUYNSEELS, A.; MAHENDIRAN, T.; MORAES, G.; SHAMDAS, M.; KERN, C.; LEDSAM, J.R.; SCHMID, M.K.; BALASKAS, K.; TOPOL, E.J.; BACHMANN, L.M.; KEANE, P.A.; DENNISTON, A.K. A comparison of deep learning performance against health-care professionals in detecting diseases from medical imaging: a systematic review and meta-analysis. **The Lancet Digital Health**, v. 1, n. 6, p. e271–e297, 2019.

LIVINGSTONE, D.; TALAI, A.S.; CHAU, J.; FORKERT, N.D. Building an Otoscopic screening prototype tool using deep learning. **Journal of Otolaryngology - Head & Neck Surgery**, v. 48, n. 1, 2019.

LUDERMIR, T. B. Inteligência Artificial e Aprendizado de Máquina: estado atual e tendências. **Estudos Avançados**, v. 35, n. 101, p. 85–94, 2021.

MADANI, A.; ARNAOUT, R.; MOFRAD, M.; ARNAOUT, R. Fast and accurate view classification of echocardiograms using deep learning. **NPJ Digital Medicine**, v. 1, n. 1, 2018.

MAHESH, M. The Essential Physics of Medical Imaging, Third Edition. **Medical Physics**, v. 40, n. 7, 2013.

MARTIN-ISLA, C.; CAMPELLO, V. M.; IZQUIERDO, C.; RAISI-ESTABRAGH, Z.; BAESSLER, B.; PETERSEN, S. E.; LEKADIR, K. Image-Based Cardiac Diagnosis With Machine Learning: A Review. **Frontiers in cardiovascular medicine**, v. 7, p. 1, 2020.

MCGLYNN, E. A.; MCDONALD, K. M.; CASSEL, C. K. Measurement Is Essential for Improving Diagnosis and Reducing Diagnostic Error: A Report From the Institute of Medicine. **JAMA**, v. 314, n. 23, p. 2501–2502, 2015.

NAGENDRAN, M.; CHEN, Y.; LOVEJOY, C. A.; GORDON, A. C.; KOMOROWSKI, M.; HARVEY, H. TOPOL, E. J.; IOANNIDIS, J. P. A.; COLLINS, G. S.; MARUTHAPPU, M. Artificial intelligence versus clinicians: systematic review of design, reporting standards, and claims of deep learning studies. **BMJ**, v. 368, 2020.

NICHOLS, J. A.; HERBERT CHAN, H. W.; BAKER, M. A. B. Machine learning: applications of artificial intelligence to imaging and diagnosis. **Biophysical Reviews**, v. 11, n. 1, p. 111–118, 2019.

OLSEN, T. G.; JACKSON, B. H.; FEESER, T. A.; KENT, M. N.; MOAD, J. C.; KRISHNAMURTHY, S.; SOANS, R. E. Diagnostic performance of deep learning algorithms applied to three common diagnoses in dermatopathology. **Journal of pathology informatics**, v. 9, n. 1, p. 32, 2018.

PEREIRA, A. L.; NASCIMENTO NETO, C. D. do; BORGES, K. F. L.; SOUZA, C. M. de; MAGIONI, M. G. L. K.; BAGGIERI, B. R. Inteligência artificial como ferramenta para identificação humana em odontologia legal. **Brazilian Journal of Production Engineering**, v. 5, n. 4, p. 82-96, 2019.

PICCOLO, D.; FERRARI, A.; PERIS KETTY; DAIDONE, R.; RUGGERI, B.; CHIMENTI, S. Dermoscopic diagnosis by a trained clinician vs. a clinician with minimal dermoscopy training vs. computer-aided diagnosis of 341 pigmented skin lesions: a comparative study. **British Journal of Dermatology**, v. 147, n. 3, p. 481-486, 2002.

RAUMVIBOONSUK, P.; KRUASE, J.; CHOTCOMWONGSE, P.; SAYERS, R.; RAMAN, R.; WIDNER, K.; CAMPANA, B. J. L.; PHENE, S.; HEMARAT, K.; TADARATI, M.; SILPA-ARCHA, S.; LIMWATTANAYINGYONG, J.; RAO, C.; KURUVILLA, O.; JUNG, J.; TAN, J.; ORPRAYOON, S.; KANGWANWONGPAISAN, C.; SUKUMALPAIBOON, R.; LUENGCHAICHAWANG, C.; FUANGKAEW, J.; KONGSAP, P.; CHUALINPHA, L.; SAREE, S.; KAWINPANITAN, S.; MITVONGSA, K.; LAWANASAKOL, S.; THEPCHATRI, C.; WONGPICHEDCHAI, L.; CORRADO, G. S.; PENG, L.; WEBSTER, D. R. Deep learning versus human graders for classifying diabetic retinopathy severity in a nationwide screening program. **NPJ digital medicine**, v. 2, n. 1, p. 1-9, 2019.

Report Linker. **Artificial Intelligence in Healthcare Market by Offering, Technology, Application, End User and Geography - Global Forecast to 2027**. Report Linker, 2021. Disponível em: <<https://www.reportlinker.com/p04897122/Artificial-Intelligence-in-Healthcare-Market-by-Offering-Technology-Application-End-User-Industry-and-Geography-Global-Forecast-to.html>>. Acesso em: 10 jun. 2022

RESMINI, R.; CONCI, A.; BORCHARTT, T. B.; LIMA, R. D. C. F. de; MONTENEGRO, A. A.; PANTALEÃO, C. A. Diagnóstico precoce de doenças mamárias usando imagens térmicas e aprendizado de máquina. **Revista brasileira de Contabilidade e Gestão**, v. 1, n. 1, p. 55-67, 2012.

SANTOS, M. K.; FERREIRA, J. R.; WADA, D. T.; TENÓRIO, A. P. M.; BARBOSA, M. H. N.; MARQUES, P. M. D.A. Inteligência artificial, aprendizado de máquina, diagnóstico auxiliado por computador e radiômica: avanços da imagem rumo à medicina de precisão. **Radiologia Brasileira**, v. 52, p. 387-396, 2019.

SENDERS, J. T.; ARNAOUT, O.; KARHADE, A. V.; DASENBROCK, H. H.; GORMLEY, W. B.; BROEKMAN, M. L.; SMITH, T. R. Natural and artificial intelligence in neurosurgery: a systematic review. **Neurosurgery**, v. 83, n. 2, p. 181-192, 2018.

TING, D. S. W.; CHEUNG, C. Y.; LIM, G.; TAN, G. S. W.; QUANG, N. D.; GAN, A.; HAMZAH, H.; GARCIA-FRANCO, R.; SAN YEO, I. Y.; LEE, S. Y.; WONG, E. Y. M.; SABANAYAGAM, C.; BASKARAN, M.; IBRAHIM, F.; TAN, N. C.; FINKELSTEIN, E. A.; LAMOUREUX, E. L.; WONG, I. Y.; BRESSLER, N. M.; SIVAPRASAD, S.; VARMA, R.; JONAS, J. B.; HE, M. G.; CHENG, C. Y.; CHEUNG, G. C. M.; AUNG, T.; HSU, W.; LEE, M. L.; WONG, T. Y. Development and Validation of a Deep Learning System for Diabetic Retinopathy and Related Eye Diseases Using Retinal Images From Multiethnic Populations With Diabetes. **JAMA**, v. 318, n. 22, p. 2211-2223, 2017.

TOH, T. S.; DONDELINGER, F.; WANG, D. Looking beyond the hype: applied AI and machine learning in translational medicine. **EBioMedicine**, v. 47, p. 607-615, 2019.

TOPOL, E. J. High-performance medicine: the convergence of human and artificial intelligence. **Nature Medicine**, v. 25, n. 1, p. 44-56, 2019.

WHITTEMORE, R.; KNALF, K. The integrative review: updated methodology. **Journal of Advanced Nursing**, v. 52, n. 5, p. 546-553, 2005.

WONG, S. H.; AL-HASANI, H.; ALAM, Z.; ALAM, A. Artificial intelligence in radiology: how will we be affected?. **European radiology**, v. 29, n. 1, p. 141-143, 2019.

YIM, J.; CHOPRA, R.; SPITZ, T.; WINKENS, J.; OBIKA, A.; KELLY, C.; ASHKAM, H.; LUKIC, M.; HUEMER, J.; FASLER, K.; MORAES, G.; MEYER, C.; WILSON, M.; DIXON, J.; HUGHES, C.; REES, G.; KHAW, P. T.; KARTHIKESALINGAM, A.; KING, D.; HASSABIS, D.; SULEYMAN, M.; BACK, T.; LEDSAM, J. R.; KEANE, P. A.; DEFAUW, J. Predicting conversion to wet age-related macular degeneration using deep learning. **Nature Medicine**, v. 26, n. 6, p. 892-899, 2020.

ZHANG, J.; GAJJALA, S.; AGRAWAL, P.; TISON, G. H.; HALLOCK, L. A.; BEUSSINK-NELSON, L.; LASSEN, M. H.; FAN, E.; ARAS, M. A.; JORDAN, C.; FLEISCHMANN, K. E.; MELISKO, M.; QASIM, A.; SHAH, S. J.; BAJCSY, R.; DEO, R. C. Fully Automated Echocardiogram Interpretation in Clinical Practice. **Circulation**, v. 138, n. 16, p. 1623-1635, 2018.

Recebido em: 2022

Aprovado em: 2022

Publicado em: 2022