

Artigo

Uma nova abordagem de aprendizado de máquina para classificação de gravidade de complicações do pé diabético usando imagens de termograma

Amith Khandakar ^{1,2}, Muhammad EH Chowdhury ^{1,*}, Mamun Bin Ibne Reaz ^{2,3}, Sawal Hamid Md Ali ^{2,4}, Serkan Kiranyaz ¹, Tawsifur Rahman ¹, Moajjem Hossain Chowdhury Mohamed ², Arselene Ayari ⁷, Rayaz A. Malik ^{3,4}, Rashad Alfkey ⁵, ²6 e Anwarul Hasan Ahmad Ashrif A. Bakar ⁷

¹ Departamento de Engenharia Elétrica, Universidade do Qatar, Doha 2713, Qatar; amithk@qu.edu.qa (AK); mkiranyaz@qu.edu.qa (SK); tawsifur.rahman@qu.edu.qa (TR)

² Departamento de Engenharia Elétrica, Eletrônica e de Sistemas, Universiti Kebangsaan Malaysia, Bangi 43600, Selangor, Malásia; sawal@ukm.edu.my (SHMA); p113968@siswa.ukm.edu.my (MHC); ashraf@ukm.edu.my (AAAB)

³ Departamento de Engenharia Civil e Arquitetônica, Universidade do Qatar, Doha 2713, Qatar; arslana@qu.edu.qa

⁴ Unidade de Inovação Tecnológica e Educação em Engenharia, Universidade do Qatar, Doha 2713, Qatar

⁵ Cirurgia de Cuidados Agudos e Cirurgia Geral, Hamad Medical Corporation, Doha 3050, Catar; rabdelmoaty@hamad.qa

⁶ Weill Cornell Medicine-Qatar, Ar-Rayyan 24144, Qatar; ram2045@qatar-med.cornell.edu

⁷ Departamento de Engenharia Industrial e Mecânica, Universidade do Qatar, Doha 2713, Qatar; ahasan@qu.edu.qa

* Correspondência: mchowdhury@qu.edu.qa (MEHC); mamun@ukm.edu.my (MBIR)



Citação: Khandakar, A.; Chowdhury,

MEH; Reaz, MBI; Ali, SHM;

Kiranyaz, S.; Rahman, T.;

Chowdhury, MH; Ayari, MA;

Alfkey, R.; Bakar, AAA; e outros. A

Nova abordagem de aprendizado de máquina

para classificação de gravidade do diabético

Complicações nos pés usando

Imagens de termograma. *Sensores* **2022**,

22, 4249. [https://doi.org/](https://doi.org/10.3390/s22114249)

10.3390/s22114249

Editor Acadêmico: Dragan Indjin

Recebido: 19 de fevereiro de 2022

Aceito: 9 de maio de 2022

Publicado: 2 de junho de 2022

Nota do editor: MDPI permanece neutro

no que diz respeito a reivindicações jurisdicionais em mapas publicados e afiliações institucionais iações.



Direitos autorais: © 2022 dos autores.

Licenciado MDPI, Basileia, Suíça.

Este artigo é um artigo de acesso aberto distribuído nos termos e

condições do Creative Commons

Licença de atribuição (CC BY) (<https://creativecommons.org/licenses/by/4.0/>).

Resumo: O diabetes mellitus (DM) é uma das doenças mais prevalentes no mundo, e está correlacionado a um alto índice de mortalidade. Uma de suas principais complicações é o pé diabético, levando a úlceras, amputação e morte. Vários estudos relatam que um termograma ajuda a detectar alterações na temperatura plantar do pé, o que pode levar a um maior risco de ulceração. No entanto, em pacientes diabéticos, a distribuição da temperatura plantar não segue um padrão padrão, dificultando a quantificação das alterações. A distribuição anormal de temperatura no infravermelho (IR) imagens de termograma do pé podem ser usadas para a detecção precoce do pé diabético antes da ulceração para evitar complicações. Não há nenhuma técnica baseada em aprendizado de máquina relatada na literatura para classificar esses termogramas com base na gravidade das complicações do pé diabético. Este artigo usa um conjunto de dados de termograma diabético rotulado disponível e usa a técnica de agrupamento k-mean para agrupar o risco de gravidade de úlceras no pé diabético usando uma abordagem não supervisionada. Usando o pé plantar temperatura, o novo conjunto de dados agrupados é verificado por médicos especialistas em termos de risco para o desenvolvimento de úlceras nos pés. O conjunto de dados recentemente rotulado é então investigado em termos de robustez para ser classificado por qualquer rede de aprendizado de máquina. Algoritmos clássicos de aprendizado de máquina com recurso engenharia e uma rede neural convolucional (CNN) com técnicas de aprimoramento de imagem são investigado para fornecer a rede de melhor desempenho na classificação de termogramas com base na gravidade. Isto descobriu-se que o popular modelo VGG 19 CNN mostra exatidão, precisão, sensibilidade, pontuação F1 e especificidade de 95,08%, 95,08%, 95,09%, 95,08% e 97,2%, respectivamente, na estratificação de gravidade. Um classificador de empilhamento é proposto usando características extraídas do termograma, que é criado usando o classificador de aumento de gradiente treinado, o classificador XGBoost e o classificador de floresta aleatório. Isso fornece um desempenho comparável de 94,47%, 94,45%, 94,47%, 94,43% e 93,25% para exatidão, precisão, sensibilidade, pontuação F1 e especificidade, respectivamente.

Palavras-chave: pé diabético; termograma; índice de mudança térmica; aprendizado de máquina; aprendizagem profunda; pé diabético; agrupamento k-média; aprendizado de máquina clássico; aprendizagem profunda; diagnóstico não invasivo técnica; classificação de gravidade do pé diabético

1. Introdução

O diabetes mellitus (DM) é uma condição médica crônica resultante de grandes quantidades de açúcar no sangue, o que muitas vezes leva a complicações graves de saúde, como doenças cardíacas

doenças, insuficiência renal, cegueira e amputação de membros inferiores [1]. O diabetes mellitus causa úlceras nos pés, que podem não cicatrizar adequadamente devido à má circulação sanguínea [2]. Isto pode resultar na propagação da infecção e, eventualmente, pode levar à amputação [3]. As amputações de membros inferiores são mais comuns em indivíduos diabéticos e, segundo as estatísticas, as lesões do pé diabético são responsáveis por 25% das internações hospitalares e 40% dos indivíduos que apresentam pé diabético necessitam de amputação [4]. A taxa de recorrência de úlceras de pé diabético (DFUs) também é significativamente alta, com aproximadamente 40% após o primeiro ano e 60% dentro de três anos após a ocorrência [5]. Num país avançado e desenvolvido como o Qatar, com mais de 20% da população diabética, é relatado que uma das razões mais comuns para as pessoas serem internadas em hospitais são as complicações do pé diabético [6]. Todos os anos, só nos EUA, mais de um milhão de pacientes diabéticos sofrem uma amputação devido à falha no reconhecimento e tratamento adequado das úlceras do pé diabético [7]. Na Europa, 250.000 pacientes diabéticos têm as pernas amputadas, com uma taxa de mortalidade de 30% num mês e 50% num ano [8]. Um paciente diabético numa categoria de “alto risco” necessita de exames regulares, cuidados pessoais higiénicos e medicação contínua e dispendiosa para evitar consequências indesejáveis. Úlceras no pé diabético levam ao aumento dos custos de saúde, diminuição da qualidade de vida, infecções, amputações e morte. A detecção precoce e melhores ferramentas de classificação de DFU permitiriam um diagnóstico correto, um tratamento eficaz e uma intervenção oportuna para prevenir futuras consequências.

O autodiagnóstico em casa, ou seja, o autocuidado, como o monitoramento sem assistência médica, para detectar sinais precoces de úlceras, pode ser útil na prevenção de sequelas graves. No entanto, a técnica de monitoramento mais fácil, a inspeção visual, tem suas limitações, como pessoas com obesidade ou deficiência visual que não conseguem ver facilmente os locais das úlceras. Alguns sistemas que permitem fácil monitoramento são TeleDiaFoS [9] e Bludrop [10]. TeleDiaFoS é um sistema de telemedicina para telemonitoramento e teleassistência domiciliar de pacientes diabéticos. Neste sistema, o pé afetado é escaneado usando um módulo de paciente especializado, que é operado com um controle remoto simples de dois botões. Embora este método tenha mostrado ótimos resultados comparáveis ao Visitrak [11] e Silhouette [12], ele requer um módulo especializado especificamente para ele. Isso pode aumentar o custo. Bludrop também introduziu um sistema patenteado que promete alta precisão, mas seu sistema também requer hardware especializado. De acordo com estudos recentes, um sistema de monitoramento de temperatura em casa foi capaz de detectar 97% das úlceras do pé diabético com bastante antecedência [13–16]. Também foi confirmado que os pacientes submetidos ao monitoramento contínuo da temperatura dos pés apresentavam baixo risco de complicações nos pés [17]. Houve estudos que tentaram encontrar a relação entre temperatura e mortalidade por diabetes [18,19], onde enfatizaram que a exposição a altas e baixas temperaturas aumenta as chances de mortalidade por diabetes, especialmente na população idosa. Foltynski et al. em [20] concluíram que a temperatura ambiente influencia a temperatura do pé mesmo durante a ulceração do pé e, portanto, deve ser levada em consideração, especialmente durante a avaliação da ulceração do pé diabético. Já na década de 1970, a monitorização da temperatura da pele surgiu como uma ferramenta útil para identificar pacientes em risco de ulceração. Na literatura, a abordagem de monitoramento da temperatura utiliza a assimetria da temperatura plantar do pé entre ambos os pés, que é chamada de “análise de assimetria”, para encontrar úlceras em estágio inicial [21]. Uma diferença de temperatura de 2,22 °C (4 °F) durante pelo menos dois dias consecutivos poderia ser usada como limite para indicar o momento de início da terapia preventiva para úlceras nos pés [14]. Verificou-se também que o sistema identificou corretamente 97% das DFUs observadas, com um prazo médio de 37 dias [22].

Portanto, um pé com temperatura elevada (>2,2 °C em comparação com o pé oposto) pode ser considerado “em risco” de ulceração devido à inflamação no local da medição.

A termografia é uma técnica popular usada para examinar alterações térmicas em um pé diabético [22]. Esta é uma técnica indolor, sem toque e não invasiva. Vários estudos propuseram técnicas baseadas em termogramas para o estudo de pés diabéticos [2,3,23], que incluem a identificação de padrões característicos em imagens infravermelhas e a medição de mudanças na distribuição térmica. Foi relatado que o grupo controle apresentou um padrão de borboleta específico [24], enquanto o grupo DM apresentou uma grande variedade de padrões espaciais [25,26].

É possível calcular e determinar uma estimativa das mudanças térmicas em relação a um pé como referência [27–30] usando a comparação contralateral de temperaturas. Porém, se ambos os pés apresentam mudanças de temperatura, mas nenhum deles apresenta o padrão borboleta, um dos pés não pode servir de referência. A assimetria não pode ser medida mesmo que haja uma grande diferença de temperatura e distribuições espaciais idênticas presentes em ambos os pés. Uma abordagem alternativa é calcular a mudança de temperatura usando um padrão borboleta de grupo de controle [31–33].

As técnicas de aprendizado de máquina (ML) estão ganhando popularidade em aplicações biomédicas para auxiliar especialistas médicos no diagnóstico precoce [34–36]. Os autores conduziram uma extensa investigação e desenvolveram um classificador AdaBoost treinado, que alcançou uma pontuação F1 de 97% na classificação de pacientes diabéticos e saudáveis usando imagens de termograma [37]. Contudo, a distribuição de temperatura de um pé diabético não possui um padrão espacial específico e é, portanto, importante desenvolver um método para distinguir os pés diabéticos com diferentes distribuições de temperatura que não dependem de um padrão espacial. A distribuição espacial pode mudar após algum tempo e as mudanças de temperatura não são significativas em alguns casos. Além disso, a detecção de aumentos irregulares de temperatura na região plantar é importante para pacientes diabéticos. A técnica de aprendizagem profunda utilizando imagens de termogramas para classificar pacientes controles e diabéticos não é um domínio bem estudado. Além disso, a classificação da gravidade do pé diabético também falta na literatura, o que pode ajudar a estabelecer uma ferramenta de alerta precoce para a detecção de úlceras no pé diabético. Uma técnica de aprendizado de máquina simples, eficaz e precisa para estratificação da gravidade do pé diabético antes do desenvolvimento de úlceras no pé usando imagens de termogramas seria muito útil.

Vários estudos [31,32,38–45] tentaram extrair características que possam ser usadas para identificar a região quente no termograma plantar, o que poderia ser um sinal de dano tecidual ou inflamação. Em todos os trabalhos a região plantar foi dividida em seis áreas e diferentes características estatísticas foram extraídas. Para obter vários coeficientes de textura e características de entropia, Adam et al. em [43] empregou uma transformação wavelet discreta (DWT) e espectros de ordem superior (HOS). Em outro trabalho, a imagem do pé foi decomposta usando uma transformada wavelet complexa de árvore dupla de densidade dupla (DD-DT-CWT), e muitos recursos foram recuperados das imagens decompostas [42]. Para categorizar os pacientes como normais ou no grupo úlcera, Saminathan et al. em [41] segmentaram a área plantar em 11 regiões usando levantamento de região e recuperaram características de textura. Maldonado et al. em [40] empregaram a abordagem DL para segmentar uma imagem visível do pé, que foi então usada para segmentar a área plantar da imagem do termograma do mesmo paciente para identificar ulceração ou necrose com base nas diferenças de temperatura. Hernández et al. em [32] apresentaram o índice de mudança térmica (ICT) como um indicador quantitativo para detecção de alterações térmicas na região plantar de pacientes diabéticos em comparação a um grupo controle de referência. Eles publicaram um banco de dados público de imagens de termogramas de pés diabéticos e o chamaram de “Banco de Dados de Termogramas Plantar”, e usaram o TCI para classificar os participantes em classes de um a cinco com base na distribuição espacial de temperatura e na faixa de temperatura. Os autores conduziram pesquisas consideráveis e produziram um classificador AdaBoost treinado que classificou pacientes diabéticos e saudáveis usando imagens de termograma com uma pontuação F1 de 97 por cento [37]. Cruz-Vega et al. em [38] propuseram uma técnica de aprendizado profundo para classificar as imagens do banco de dados de termogramas plantares em um esquema de classificação não conveniente, onde os resultados foram mostrados fazendo duas aulas por vez e calculando a média dos resultados após dez dobras de uma combinação diferente de dois definir aulas. Para a classificação da classe três e classe quatro, foi proposta uma nova rede de termogramas do pé diabético (DFTNet), com sensibilidade e precisão de 0,9167 e 0,853, respectivamente. Entretanto, a classificação verdadeira dos pacientes neste banco de dados foi realizada por meio do escore TCI, que utiliza o padrão borboleta do grupo controle que é utilizado individualmente para comparar cada pé afetado. Portanto, a classificação depende inteiramente da confiabilidade da técnica de pontuação do TCI, que foi considerada questionável em dois aspectos diferentes. Primeiramente observou-se que as imagens de termogramas com padrão borboleta mesmo presentes nas classes mais altas e a distribuição de temperatura dos pacientes diabéticos graves relatada em outros artigos foram classificadas incorretamente nas classes mais baixas

com base na pontuação do TCI. Em segundo lugar, as técnicas de aprendizagem profunda de última geração não conseguiram classificar de forma confiável as imagens do termograma em diferentes classes, que foram classificadas com base na pontuação do TCI. Se um banco de dados estiver disponível publicamente, é fácil reavaliar os rótulos nos conjuntos de dados se for descoberto que os rótulos são questionáveis [46]. Aradillas et al. [47] mencionaram cenários onde encontraram erros na rotulagem das amostras de treinamento em bancos de dados e propuseram técnicas de validação cruzada para removê-los. Hu et al. [48] mencionaram rótulos errados em bancos de dados de reconhecimento facial e propuseram um paradigma de treinamento que levaria em conta o tamanho do conjunto de dados e treinaria removendo probabilisticamente alguns conjuntos de dados que poderiam ter sido rotulados incorretamente. Ding et al. [49] propuseram uma abordagem semissupervisionada de dois estágios no aprendizado de rótulos ruidosos.

De acordo com a discussão acima, pode-se observar que há uma falta de classificação da gravidade do risco de desenvolvimento de úlcera. Os autores, incluindo um conjunto de médicos especialistas que trabalham numa clínica de pés diabéticos, afirmaram que a distribuição da temperatura plantar do pé pode ajudar na detecção precoce do desenvolvimento de uma úlcera no pé [50–52]. A hipótese científica deste trabalho é se abordagens de aprendizado de máquina podem ser usadas para categorizar termogramas em classes de gravidade de pacientes com risco de desenvolvimento de úlcera. Essa classificação de gravidade pode ajudar no tratamento precoce que pode prevenir úlceras no pé diabético. O desempenho aprimorado de um modelo de aprendizado de máquina poderia ajudar na detecção precoce a partir da conveniência da casa do paciente e reduzir a carga sobre os sistemas de saúde, considerando que as complicações do pé diabético são muito comuns e levam a procedimentos caros de acompanhamento e tratamento em todo o mundo. Todos os estudos acima motivaram os autores a realizar uma extensa investigação sobre a re-rotulagem de conjuntos de dados, usando um aprendizado de máquina não supervisionado e uma rede neural convolucional pré-treinada (CNN) para extrair recursos automaticamente de imagens de termogramas, reduzir a dimensionalidade dos recursos usando a análise de componentes principais (PCA) e, finalmente, classificar os termogramas usando agrupamento k-mean [53] para Os novos rótulos identificados pelos clusters não supervisionados foram ajustados por um grupo de médicos (MDs). Em seguida, os autores investigaram técnicas clássicas de aprendizado de máquina usando engenharia de recursos e CNNs 2D com técnicas de aprimoramento de imagem nas imagens para desenvolver a rede de classificação de melhor desempenho. As principais contribuições deste artigo podem ser declaradas da seguinte forma:

A revisão dos rótulos do conjunto de dados de termogramas para a classificação da gravidade do diabetes de um conjunto de dados de termogramas publicamente disponível usando aprendizado de máquina não supervisionado (agrupamento K-mean), que é ajustado por médicos (MDs).

A extração e classificação de características relevantes de pixels de temperatura para classificação de termogramas em grupos de gravidade diabética.

A exploração do efeito de várias técnicas de aprimoramento de imagem em imagens de termogramas na melhoria do desempenho de modelos 2D CNN na classificação da gravidade do diabetes.

Este trabalho é o primeiro desse tipo a propor uma técnica de aprendizado de máquina para classificar termogramas diabéticos em diferentes classes de gravidade: leve, moderada e grave.

O manuscrito está organizado em cinco seções, onde a Seção 1 discute a introdução e os trabalhos relacionados e principais contribuições, a Seção 2 discute a metodologia detalhada utilizada neste trabalho e as Seções 3 e 4 apresentam os resultados e discussão.

Por fim, a Seção 5 apresenta as conclusões.

2. Metodologia A

metodologia adotada no trabalho é apresentada na Figura 1. No estudo, o termograma foi aplicado a um modelo CNN pré-treinado para extrair recursos úteis e, em seguida, a dimensionalidade do recurso foi reduzida usando análise de componentes principais (PCA), e o espaço de recursos esparsos foi então aplicado como uma entrada para o algoritmo de agrupamento k-mean para fornecer classes revisadas não supervisionadas, que foram então verificadas por médicos. As classes recém-revisadas – leve, moderada e grave – foram então testadas em termos de desempenho de classificação pela abordagem CNN 2D usando diferentes técnicas de aprimoramento de imagem e algoritmos clássicos de aprendizado de máquina nas características extraídas dos termogramas. As seções a seguir abordaram o conjunto de dados usado no estudo, o método de agrupamento K-mean

Diabetic Patient Thermograms

K-mean clustering
(Unsupervised learning using extracted features)

ground truth labels

K Means Clustering using $k = 3$

Class 1
Class 2
Class 3
Class 4
Class 5

Revised severity classes
(Mild, Moderate and Severe)

Mild Moderate Severe

Severity classification verified by medical experts

Investigation with the help of 2D CNN and Image Enhancement

Feature Extraction from thermograms and Feature Engineering on different Classical Machine Learning Algorithm

Mild Moderate Severe

Mild Moderate Severe

2.1. Conjunto de dados

[illegible]




Figura 2. Amostra de angiossomas MPA, LPA, MCA e LCA do pé para controle e diabético grupos [37].

2.2.2. Classificação não supervisionada de agrupamento K-mean

Nesta parte da investigação, os caracteres subjacentes das imagens de termografia de pé foram extraídos usando um modelo CNN pré-treinado. O CNN pré-treinado foi usado para extrair recursos de agrupamento k-mean. K-mean é um algoritmo de agrupamento não supervisionado e foi proposto em 1967. [53]. K-mean é um método de agrupamento não supervisionado, não determinístico, numérico e iterativo. Em k-mean, cada cluster é representado pelo valor médio dos objetos no cluster. Aqui, particionamos um conjunto de n objetos em k clusters, de modo que a similaridade entre clusters fosse baixa e a similaridade entre objetos dentro de um cluster fosse alta. A similaridade foi medida em termos do valor médio dos objetos em um cluster. Um conceito semelhante foi utilizado em nossa investigação e pode ser dividido em 4 etapas:

A. Pré-processamento: Preparando a imagem para que ela possa ser alimentada adequadamente na CNN modelo.

B. Extração de recursos: usando um modelo CNN pré-treinado para extrair os recursos subjacentes de uma camada específica.

C. Redução de dimensionalidade: Usando análise de componentes principais (PCA) [55] para reduzir o ruído no espaço de recursos e reduzir a dimensionalidade.

D. Clustering: Usando K-mean para agrupar as imagens com base em recursos semelhantes.

Na etapa de pré-processamento, a imagem foi primeiro redimensionada para o tamanho 224×224 . Isso foi feito porque o modelo CNN disponível em Keras [56], pré-treinado no ImageNet Dataset [57], exigia que a imagem de entrada fosse desse tamanho. A interpolação foi aplicada às imagens antes do redimensionamento para permitir o redimensionamento por um fator de escala não inteiro. Esta etapa não alterou a estrutura detalhada, juntamente com a arquitetura de rede, pode ser vista na Figura 3. O modelo pré-VGG19 foi usado para extrair 4.096 recursos da camada 'FC1' de cada termograma.

O modelo VGG19 treinado foi usado para extrair 4.096 recursos da camada 'FC1' de cada imagem. A seleção da camada de rede para extração de características foi um hiperparâmetro em nosso estudo, foi utilizada a popular rede CNN - VGG19 [58].

A rede VGG19 desenvolvida pelo Oxford Visual Geometry Group é uma rede CNN popular para tarefas de visão computacional devido ao seu alto desempenho e relativa simplicidade. A estrutura, juntamente com a arquitetura de rede, pode ser vista na Figura 3. O pré-treinado

a estrutura detalhada, juntamente com a arquitetura de rede, pode ser vista na Figura 3. O modelo pré-VGG19 foi usado para extrair 4.096 recursos da camada 'FC1' de cada termograma.

O modelo VGG19 treinado foi usado para extrair 4.096 recursos da camada 'FC1' de cada imagem. A seleção da camada de rede para extração de características foi feita por este experimento e foi ajustada para obter o parâmetro que proporcionou o melhor resultado.

Descobrimos empiricamente que a camada 'FC1' nos deu o melhor resultado, que é um exercício comum.

Descobrimos empiricamente que o resultado da camada 'FC1' é semelhante a outros estudos que investigaram o agrupamento k-means [59,60]. O número de recursos precisava ser reduzido para que o algoritmo k-mean não se ajustasse excessivamente ao ruído. PCA foi usado para transformar e reduzir os recursos de tal forma que apenas os recursos mais importantes foram retidos [51]. A Figura 4 mostra a variância cumulativa versus componentes após PCA. Pode-se observar que os primeiros 10 componentes fornecidos uma variância de 0,5, e após adicionar mais 90 componentes, a variância sobiu para 0,9. Assim, informações significativas foram retidas nos componentes iniciais. Em nosso estudo, nos

primeiros 10 componentes, a variância aumentou para 0,9. Assim, informações significativas foram retidas nos componentes iniciais.

Em nosso estudo, usamos 45 componentes para alcançar o valor 75% da variância acumulada, o que geralmente é um limite aceitável em vários estudos de agrupamento k-mean [61–64].

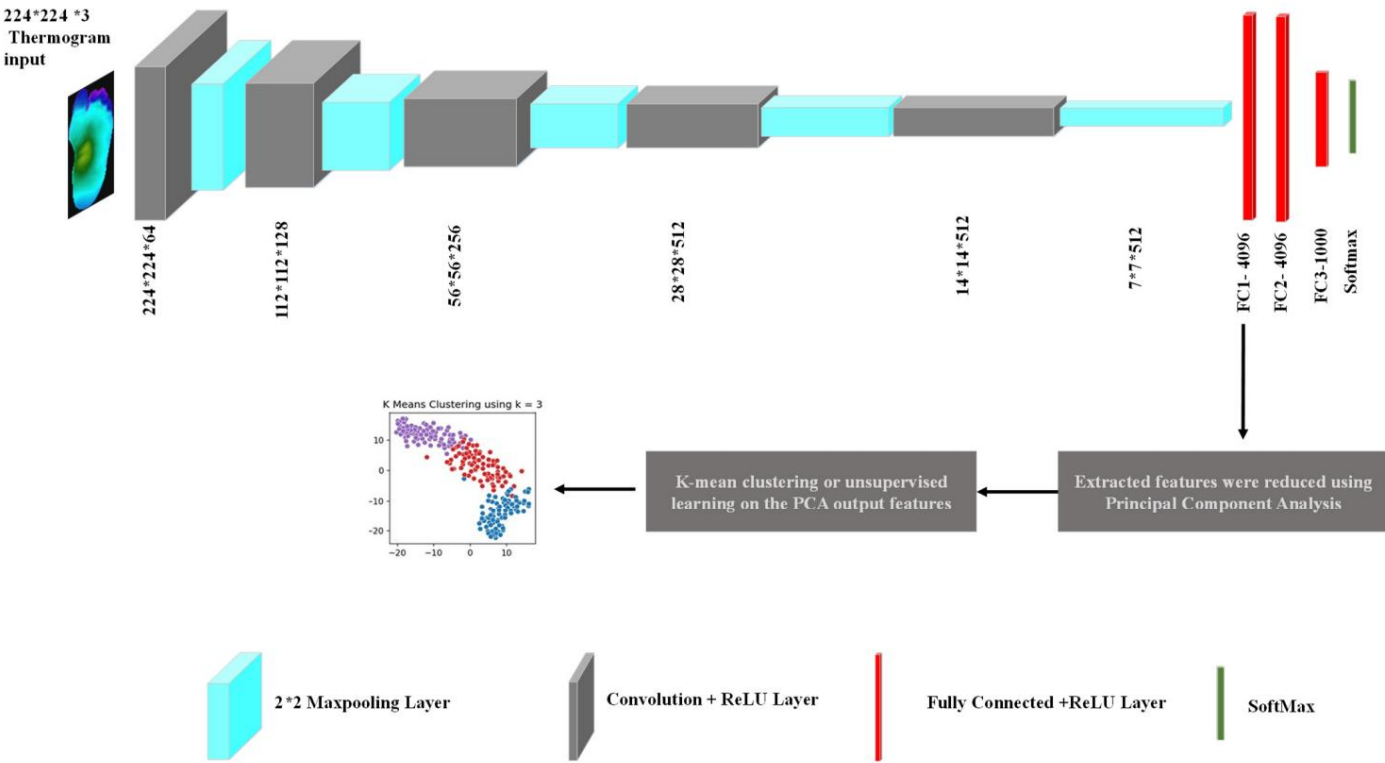


Figura 3. Estrutura detalhada de agrupamento de imagens de termogramas.




Figura 4. Variância acumulada versus número de componentes do PCA.

Os recursos reduzidos e transformados foram separados em diferentes grupos usando o algoritmo de agrupamento k-mean [65]. Este é um algoritmo de aprendizado de máquina não supervisionado, que significa clustering ou k-mean [65]. Este é um algoritmo de agrupamento de dados não rotulados [66,67]. O objetivo do K-mean era agrupar dados que foram lidos e lidos no espaço de recursos. O fluxo do algoritmo pode ser visto no Algoritmo 1 abaixo. Em nosso estudo, max_iter foi definido como 500 e a condição de quebra que aconteceu somente após a linha 4 foi cumprida para todos os clusters.

Algoritmo 1: agrupamento K-mean**Entrada :** matriz de recursos, número de centróides (k)**Saída :** modelo treinado

```

1: para i  $\tilde{y}$  1 para max_iter faça
2: Atribua a cada ponto o centróide que está mais próximo no espaço latente;
3: Recalcular a posição dos clusters (centroid_position) para ser igual à posição média de todos os seus pontos associados; 4: se centroid_positioni == centroid_positioni-1 então 5: break; 6: eu++; 7: fim para

```

O algoritmo teve como objetivo reduzir a inércia. A inércia é a soma das distâncias euclidianas quadradas de um centróide aos seus pontos de dados associados e pode ser vista matematicamente na Equação (1).

$$\text{Inércia} = \sum_{j=1}^k \sum_{eu=1}^n x_{ij}^{(j)} - y_{cj}^{(j)} \quad (1)$$

onde k é o número total de clusters, n é o número de amostras associadas a um cluster, x é a posição da amostra no espaço de recursos e c é a posição do centróide no espaço de recursos.

K-means++ [68] foi usado para inicializar a posição do centróide. Este método ajudou a alcançar um bom desempenho de clustering e reduziu a complexidade computacional. Neste método, o primeiro centróide foi selecionado a partir dos dados com probabilidade uniforme. Os demais centróides foram selecionados a partir dos dados com probabilidade proporcional à distância do centróide mais próximo. Consequentemente, os centróides iniciais estavam próximos dos pontos de dados, mas distantes uns dos outros.

Conforme afirmado anteriormente, o conjunto de dados rotulado fornecido pelo agrupamento k-mean foi usado para a investigação usando (i) aprendizagem por transferência, aprimoramento de imagem e aprendizagem por transferência 2D CNN e (ii) técnicas clássicas de aprendizado de máquina e engenharia de recursos nos recursos extraídos do termogramas.

2.3. Classificação bidimensional baseada em CNN

A CNN bidimensional é amplamente utilizada em aplicações biomédicas para diagnóstico automático e precoce de anomalias como pneumonia por COVID-19, tuberculose e outras doenças [69,70]. Um conjunto de dados rotulado pode ser dividido em conjuntos de dados de treinamento e teste, com o conjunto de dados de treinamento sendo usado para treinar a rede e o conjunto de dados de teste invisível sendo usado para verificar seu desempenho. Durante o processo de treinamento, uma parte do conjunto de dados de treinamento é usada para validação para evitar overfitting. A validação cruzada quádrupla foi empregada neste estudo, que dividiu o conjunto de dados em cinco vezes e encontrou a métrica de desempenho para o conjunto de dados de teste cinco vezes. Cada vez, uma das dobras foi usada como conjunto de dados de teste e as dobras restantes foram usadas para treinamento e validação. Essa abordagem ajudou a declarar os resultados considerando o conjunto de dados completo e garantindo que os dados de teste sempre fossem invisíveis. Os resultados finais foram o resultado global e ponderado das cinco dobras; a métrica de desempenho detalhada foi mostrada posteriormente. Como uma maior quantidade de dados utilizados para treinamento sempre ajuda na obtenção de um modelo melhor treinado, os autores utilizaram técnicas populares de aumento (rotação e tradução) para aumentar o tamanho dos dados de treinamento. A operação de rotação utilizada para aumento da imagem foi realizada girando as imagens nos sentidos horário e anti-horário com ângulos de 5 a 30 em incrementos de 5°. A operação de tradução de imagens foi realizada traduzindo imagens horizontalmente e verticalmente de -15 a 15%. Os detalhes do conjunto de dados de treinamento, validação e teste para classificador binário e de gravidade 2D são mostrados na Tabela 1.

Tabela 1. Detalhes do conjunto de dados usado para treinamento (com e sem aumento), validação e teste.

Tabela 1. Detalhes do conjunto de dados usado para treinamento (com e sem aumento), validação e teste de detalhes do conjunto de dados

Contagem de mogramas/cluster de validação aumentada de treinamento terapêutico para						Teste
Conjunto de dados do classificador		diabéticos (60% dos dados)			Treinar Thermo-(20% dos dados)	(20% do
Classificador	Conjunto de dados	Identificado no artigo		Validação		Dados de Im-
		Termogramas/Cluster	(60% dos dados)	Trem Aumentado/Dobrar	(20% dos dados)	Idade/Dobra
		Identificado no artigo Leve	Termograma Dobrado Dobrar	2040 Dobrar	Termograma Dobrado Dobrar	11 Imagem/Dobra
Gravidade ras et al.	Contreras	Moderado Leve	4813	2242040	4 3 4	111
Gravidade [39]	e outros. [39]	Forte Moderado Forte	48 93	2244 1806	7	11 24

Aprendizagem por transferência: Como tínhamos um conjunto de dados limitado, que pode ser visto na Tabela 1, poderíamos fazer uso de modelos pré-treinados que foram treinados em um grande banco de dados ImageNet [71], fazer uso de

Essas redes pré-treinadas foram treinadas em um banco de dados ImageNet muito grande [71] e tiveram bom desempenho de classificação. Essas redes poderiam ser treinadas posteriormente em qualquer outro bom

Essas redes pré-treinadas foram treinadas em um banco de dados ImageNet muito grande [71] e tiveram desempenho de classificação. Essas redes poderiam ser treinadas posteriormente em qualquer outro bom desempenho de classificação. Estas redes poderiam ser treinadas em qualquer outro problema de classificação. Isso é conhecido como transferência de aprendizado. Baseado em um extenso

desempenho de classificação. Estas redes poderiam ser treinadas em qualquer outro problema de classificação, e isso é conhecido como aprendizado por transferência. Baseado em um extenso problema de classificação de literatura, conhecido como aprendizado por transferência. Com base em extensa revisão de literatura e desempenhos anteriores [37], neste estudo, sete revisões de literatura pré-treinadas bem conhecidas e desempenhos anteriores [37], neste estudo, sete modelos CNN pré-profundos bem conhecidos foram usados para classificação dos termodiagramas. ResNet8, ResNet50, ResNeXt e outros modelos CNN foram utilizados para

desempenhos anteriores [37], neste estudo, sete modelos CNN pre-profundos bem conhecidos foram usados para classificação dos termogramas: ResNet18, ResNet50, Restrained deep models CNN foram utilizados para classificação dos termogramas: ResNet18, ResNet50, InceptionV3 [73], VGG19 [58] e MobileNetV2 [74].

ResNet100 [72], DenseNet201 [72], InceptionV3 [73], VGG19 [58] e MobileNetV2 [74].

Aprimoramento de imagem: Verificou-se que técnicas de aprimoramento de imagem, como adaptativas. Apimoramento de imagem: Verificou-se que técnicas de aprimoramento de imagem, como adaptativas. equalização de histograma (AHE) [75] e correção gama [70, 76] podem ajudar a CNN 2D na equalização de histograma (AHE) [75] e correção gama [70, 76] podem ajudar a CNN 2D melhorando seu desempenho de classificação para termogramas [37]. Algumas amostras do im- na melhoria de seu desempenho de classificação para termogramas [37]. Algumas amostras do o realce da imagem no DM e no GC pode ser observado na Figura 5. Os autores investigaram o realce da imagem no DM e no GC pode ser observado na Figura 5. Os autores investigaram melhoria do desempenho possibilitada pelas diferentes tecnologias de aprimoramento de imagem - a melhoria do desempenho possibilitada pelos diferentes aprimoramentos de imagem técnicas, e elas foram relatadas na seção Resultados Experimentais. técnicas, e elas foram relatadas na seção Resultados Experimentais.

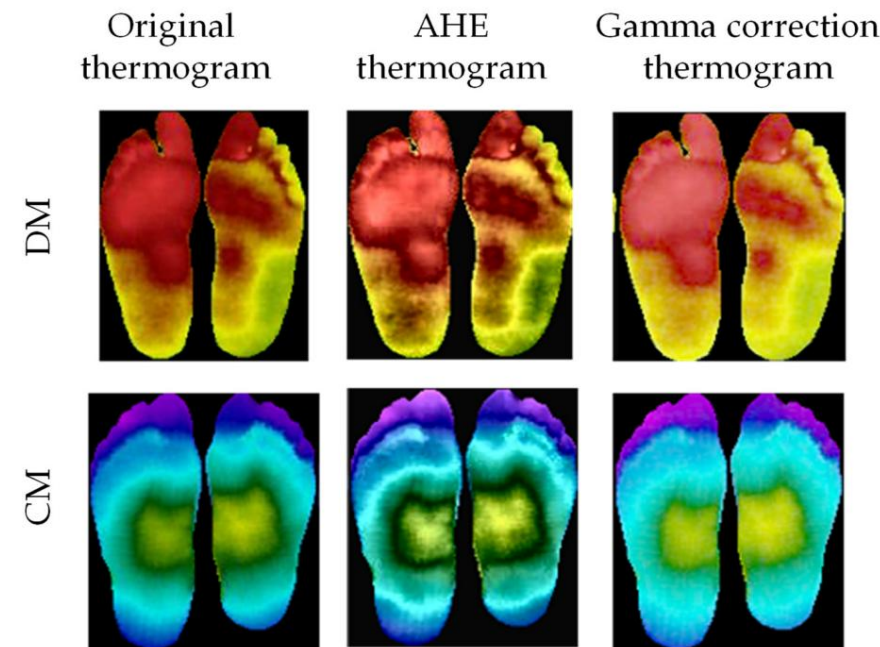


Figura 5. Termograma original versus termograma aprimorado usando AHE e correção gama para DM e GG [37].

2.4. Abordagem Clássica de Aprendizado de Máquina

Esta seção discute os recursos extraídos para técnicas clássicas de ML, recursos, técnicas de classificação de recursos, classificadores de aprendizado de máquina e as técnicas de ex-redução, além das investigações realizadas usando duas abordagens.

2.4.1. Recursos extraídos e redução de recursos

Os autores examinaram cuidadosamente a literatura para resumir os recursos usados na prática clínica e nas abordagens de aprendizado de máquina para analisar os termogramas dos pés para o diagnóstico do pé diabético. Os detalhes da lista final de características identificadas pelos autores foram mencionados em seu trabalho anterior em [37] e também mencionados abaixo:

$$\text{Índice de Mudança Térmica (TCI)} = 4 \frac{\text{CGang} - \text{DMang}}{\text{CGang} + \text{DMang}} \quad (2)$$

onde CGang e DMang são os valores de temperatura do angiossoma para o grupo controle e um sujeito DM, respectivamente.

$$\text{Temperatura estimada (ET)} = \frac{a_j \bar{y}_1 C_j \bar{y}_1 + a_j C_j + a_{j+1} C_{j+1}}{a_j \bar{y}_1 + a_j + a_{j+1}} \quad (3)$$

$$\text{Diferença de temperatura estimada (ETD)} = |\text{ET}_{\text{le ft Angiossoma}} - \text{Angiossoma ET}_{\text{right}}| \quad (4)$$

$$\text{Estimador de Hot Spot (HSE)} = |c_l - \text{ET}| \quad (5)$$

Um histograma para a porcentagem de pixels no termograma (pé completo ou angiossomas) nas diferentes temperaturas de classe ($C_0 = 26,5$ °C, $C_1 = 28,5$ °C, $C_2 = 29,5$ °C, $C_3 = 30,5$ °C, $C_4 = 31$ °C, $C_5 = 32,5$ °C, $C_6 = 33,5$ °C e $C_7 = 34,5$ °C) foi gerado para igualar os parâmetros nas Equações (3)–(5). A temperatura classmark e a porcentagem associada de pixels naquela região foram denotadas pelos termos C_j e a_j , respectivamente. A porcentagem de pixels nas temperaturas de classe circundantes $C_j \bar{y}_1$ e C_{j+1} foram representadas pelos valores $a_j \bar{y}_1$ e a_{j+1} , respectivamente.

Além desses parâmetros, os autores formularam $\text{NRT}_{\text{classe } j}$, que era o número de pixels na faixa de temperatura da classe j sobre o número total de pixels diferentes de zero, onde a classe j poderia ser a classe 1 a 5. Este parâmetro é visualmente muito importante para distinguir a variação na distribuição da temperatura plantar, e também foi relatado em trabalhos anteriores dos autores [37].

Assim, TCI, valor de temperatura mais alto, NTR (classe 1–5), HSE, ET, ETD, média, mediana, DP de temperatura para os angiossomas distintos, LPA, LCA, MPA, MCA e pé inteiro estavam entre as 37 características que poderiam ser empregados para identificação precoce do pé diabético. Em seu estudo anterior [37], os autores publicaram as estatísticas dos dados fornecidos pela fonte [39].

Ao determinar a associação entre os vários recursos, a lista final de recursos foi simplificada para eliminar recursos redundantes. Recursos com correlação superior a 95% foram excluídos, melhorando o desempenho geral ao diminuir o número de recursos redundantes e evitando overfitting [77,78].

2.4.2. Classificadores de aprendizado de

máquina Os autores também exploraram diferentes classificadores de aprendizado de máquina (ML) neste estudo para comparar os desempenhos. Os classificadores de ML populares usados no estudo foram perceptron multicamadas (MLP) [79], máquina de vetores de suporte (SVM) [80], floresta aleatória [81], árvore extra [82], GradientBoost [83], regressão logística [84], K-vizinho mais próximo (KNN) [85], XGBoost [86], AdaBoost [87] e análise discriminante linear (LDA) [88].

2.4.3. Abordagem clássica de aprendizado de máquina 1: combinação ideal de classificação de recursos, número de recursos

Após a otimização, os parâmetros pré-selecionados do conjunto de dados foram avaliados para determinar decisões e os melhores recursos para classificação de gravidade. O aumento de gradiente extremo de múltiplas árvores (XGBoost) [89], floresta aleatória [90], árvore extra [91], qui-quadrado [92], coeficiente de correlação de Pearson [93], eliminação de recursos recursivos (RFE) [94], regressão logística [95] e LightGBM [96] foram usados para identificar três conjuntos diferentes de classificação de recursos. Pesquisas rigorosas determinaram a maior combinação de recursos que ofereciam o melhor desempenho

taset S, que consistia em exemplos $= (x_i, y_i)$, ou seja, pares de vetores de características (x_i) e suas classificações (y_i) . Uma coleção de classificadores de nível básico foi treinada na primeira fase, onde $M = \{M_1, M_2, \dots, M_N\}$. Um classificador de metanível foi treinado na segunda etapa, que integrou as saídas dos classificadores de nível base (Figura 6).

Uma abordagem de validação cruzada foi usada para construir um conjunto de treinamento para aprender o meta-classificador de nível. Aplicamos cada um dos algoritmos de aprendizagem de nível básico a quatro dobras do conjunto de dados para validação cruzada de cinco vezes, deixando uma dobra para teste. Uma distribuição de probabilidade sobre os possíveis valores de classe foi prevista por cada classificador de nível base. Quando aplicado e os recursos classificados com melhor desempenho dos diferentes métodos de classificação de recursos para o exemplo x , a previsão do classificador de nível básico M foi uma distribuição de probabilidade: gies foram usadas para identificar a melhor combinação de recursos.

$(y_i) = ((y_1), (y_2), \dots, (y_N))$, (2.4.4. Abordagem de empilhamento)

(y_i) significa a probabilidade de que o exemplo x pertencesse à classe conforme estimado. Apresentamos um classificador baseado em empilhamento que funcionou mesclando vários melhores (e previstos) pelo classificador M , onde (y_1, y_2, \dots, y_N) é o conjunto de classes possíveis valores, realizando classificadores criados por diferentes algoritmos de aprendizagem de nível básico. O conjunto de metadados S , que consistia em exemplos $s_i = (x_i, y_i)$, ou seja, pares de vetores de características (x_i) e suas classificações (y_i) . Uma coleção de classificadores de nível básico M_1, \dots, M_N foi treinado em fase, onde $M = \{M_1, M_2, \dots, M_N\}$. Um classificador de meta-nível foi treinado na segunda etapa, para suas saídas dos classificadores de nível base (Figura 6).

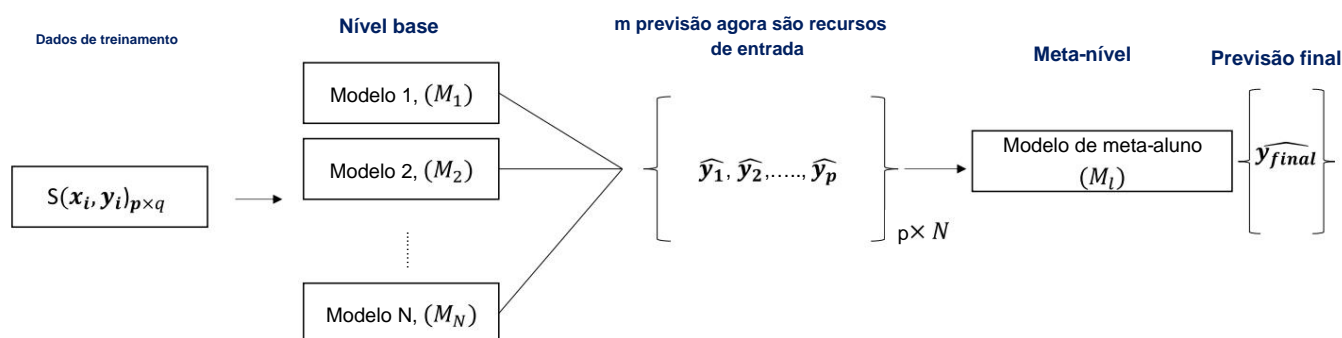


Figura 6. Representação esquemática da arquitetura do modelo de empilhamento.

2.5. Esquema de avaliação e classificação de desempenho Uma abordagem de validação cruzada foi usada para construir um conjunto de treinamento para aprender o meta-classificador. Aplicamos cada um dos algoritmos de aprendizagem de nível básico a quatro dobras do conjunto de dados para validação cruzada de cinco vezes, deixando uma dobra para teste. Uma distribuição de probabilidade sobre os possíveis valores de classe foram previstos por cada classificador de nível base. Quando aplicado ao exemplo

x , a previsão do classificador de nível básico M foi uma distribuição de probabilidade: (7)

$$P M(x) = P M(c_1|x), P M(c_2|x), \dots, P M(c_m|x), (+) (8)$$

$P M(c_i | x)$ significa a probabilidade de que o exemplo x pertencesse à classe c_i conforme estimado (e previsto) pelo classificador M , onde (c_1, c_2, \dots, c_m) é o conjunto de possíveis valores de classe. O classificador M previu a classe c_j com a maior probabilidade de classe $P M(c_j | x)$. As características de meta-nível são as probabilidades previstas por cada um dos classificadores de nível base para cada classe concebível, ou seja, $P M_j(c_i | x)$ para $i = 1, \dots, m$ e $j = 1, \dots, N$, onde (c_1, c_2, \dots, c_m) é o conjunto de valores de classe possíveis e $P M(c_i | x)$ denota: (11)

2.5. Esquema de Avaliação e Classificação de Desempenho

Em todos os nossos experimentos, relatamos sensibilidade, especificidade, precisão, exatidão, Pontuação F1 e área sob a curva (AUC) para cinco dobras, como nossas métricas de avaliação.

$$\text{Sensibilidade} = \frac{TP}{TP + FN} \quad (7)$$

$$\text{Especificidade} = \frac{TN}{TN + FP} \quad (8)$$

$$\text{Precisão} = \frac{TP}{TP + FP} \quad (9)$$

$$\text{Precisão} = \frac{TP + TN}{TP + FN + FP + TN} \quad (10)$$

$$\text{Pontuação F1} = \frac{2 \times \text{Precisão} \times \text{Sensibilidade}}{(\text{Precisão} + \text{Sensibilidade})} \quad (11)$$

Aqui, TP, FP, TN e FN são verdadeiros positivos, falsos positivos, verdadeiros negativos e falsos negativos. Em qualquer classificação, TP é o número de termogramas identificados corretamente, TN é o número de termogramas corretamente identificados da outra classe, FP é o número de termogramas classificados incorretamente e FN é o número de termogramas da outra classe classificados incorretamente. Neste artigo, uma métrica de desempenho ponderada com intervalo de confiança de 95% foi relatada para sensibilidade, especificidade, precisão e pontuação F1, e para a exatidão, a exatidão geral foi relatada.

Todos os experimentos foram feitos na plataforma google colab e utilizaram GPU GeForce RTX2070 Super que é fabricada pela NVIDIA, localizada em Santa Clara, CA, EUA. O outro software foi o Matlab da Mathworks, Natick, MA, EUA.

3. Resultados Experimentais

Esta seção do artigo fornece os resultados de vários experimentos importantes de o papel. Os detalhes estão abaixo:

3.1. Classificação não supervisionada de agrupamento

K-mean Como afirmado na seção anterior, o agrupamento k-mean foi usado para classificar as imagens do termograma de maneira não supervisionada. Isso foi feito utilizando as características extraídas da rede VGG-19, que posteriormente foram reduzidas e transformadas por meio de PCA. O agrupamento K-mean foi aplicado para vários números de cluster, ou seja, k no Algoritmo 1. O número ideal de clusters seria equivalente à classe de gravidade correta dos termogramas, posteriormente verificada por médicos especialistas. Os gráficos de incorporação estocástica de vizinhos distribuídos em T (t-SNE), que são muito úteis na visualização do agrupamento de dados em duas dimensões [97,98], para vários clusters podem ser vistos na Figura 7. O t-SNE é uma dimensão - método de redução de funcionalidade usado para visualizar dados de alta dimensão. Neste trabalho, o espaço de características de alta dimensão foi visualizado reduzindo-o a duas dimensões usando t-SNE e depois plotando-o em um gráfico de dispersão. Ficou evidente que havia uma distinção clara no agrupamento para os tamanhos de cluster dois e três em comparação com um tamanho de cluster de cinco (classificação original realizada usando pontuações do TCI, ou seja, classe um – classe cinco). Conforme indicado na Figura 4, 45 componentes foram usados no agrupamento k-mean.

Os clusters encontrados usando a abordagem de agrupamento k-mean foram confirmados por especialistas no domínio de complicações do pé diabético como termogramas de pacientes com gravidade leve, moderada e grave, e podem ser vistos na Figura 8. Os especialistas usaram sua experiência com temperatura plantar do pé distribuição entre pacientes diabéticos como referência para confirmação da classificação de gravidade. Os clusters encontrados pelo agrupamento k-mean forneceram três conjuntos diferenciáveis de termogramas. Termogramas plantares do pé com padrão de borboleta ligeiramente desviado foram rotulados como leves por especialistas médicos. O segundo conjunto de termogramas plantares do pé onde havia uma distribuição anormal e de alta temperatura foi rotulado como moderado pelos médicos especialistas, pois as distribuições de temperatura ainda não eram muito altas (o que geralmente é indicado pela distribuição de cor vermelha nos termogramas) e poderia indicar a possibilidade de desenvolvimento de úlcera em um futuro próximo. O terceiro conjunto de termogramas plantares do pé apresentava temperatura extremamente alta (geralmente indicada pela distribuição de cor vermelha nos termogramas) em todo o pé, indicando a possibilidade de desenvolvimento de úlcera no futuro imediato, e foi rotulado como grave. Tal agrupamento não foi encontrado na classificação original usando o método baseado em TCI (ou seja, classe um – classe cinco). O algoritmo de agrupamento separou as imagens em três agrupamentos. A classe leve teve 82 imagens, a classe moderada teve 84 imagens e a classe grave teve

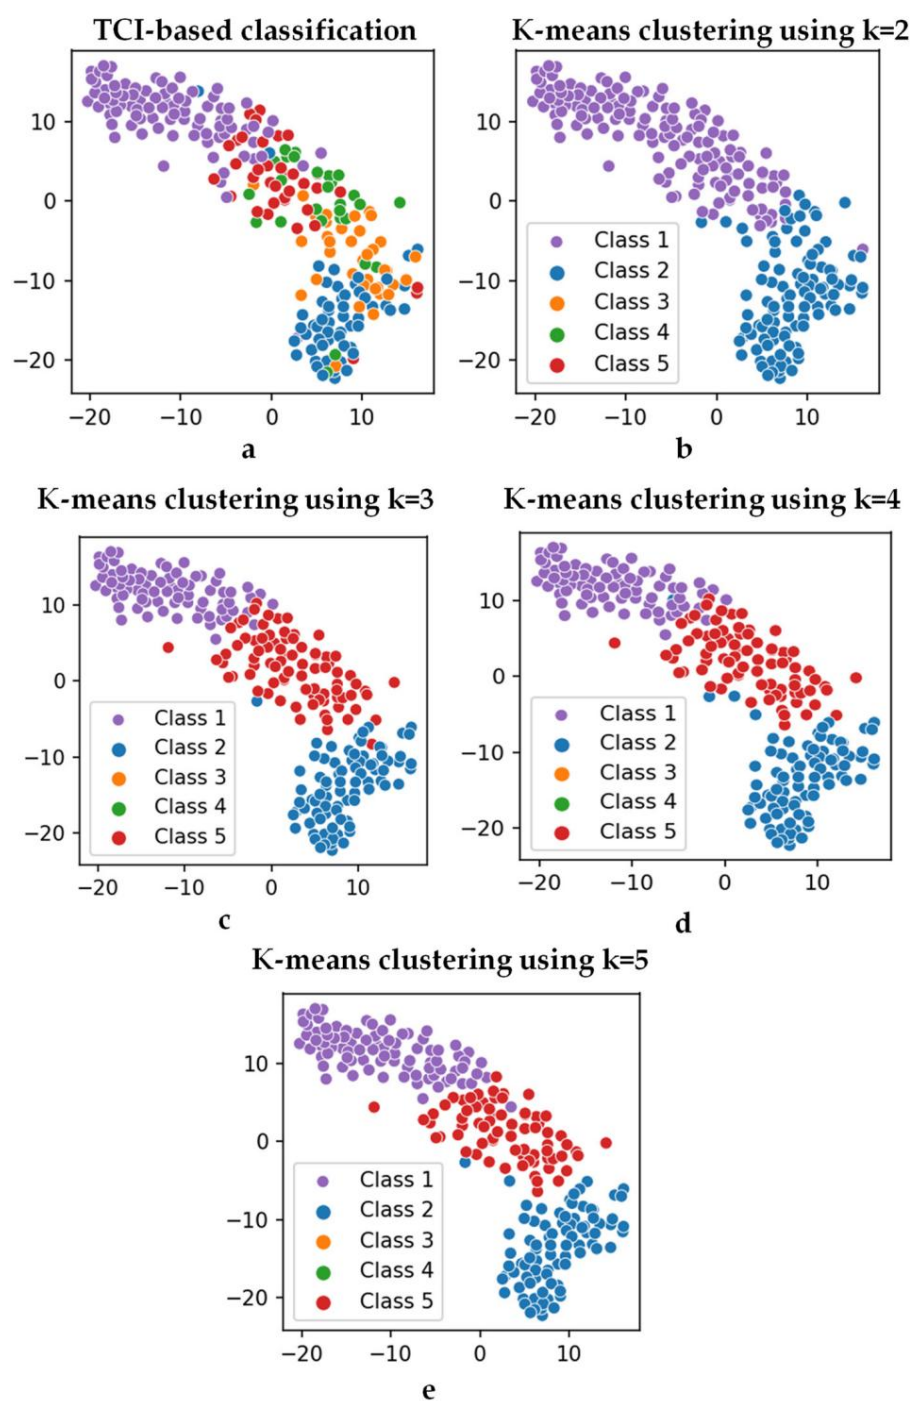


Figura 7. Gráficos t-SNE com (a) classes baseadas em TCI (classe 1 – classe 5) e saída de k-mean clustering com (b) k = 2, (c) k = 3, (d) k = 4 e (e) k = 5.

A saída do agrupamento k-mean pode ser melhor compreendida com a ajuda de especialistas nos gráficos de pizza da Figura 9, que mostram a distribuição das classes nos diferentes no domínio complicações do pé diabético como termogramas de pacientes com agrupamentos leves e moderados encontrados pela abordagem de agrupamento k-mean. Pode-se ver claramente que muitas classes e gravidade grave, e pode ser visto na Figura 8. Os especialistas usaram sua experiência com um termograma que era muito semelhante ao termograma da classe cinco (consulte a classe grave em gráfico de pizza) e muitas classes três, classes quatro e classes cinco foram semelhantes às classes um e dois (consulte a classe suave no gráfico de pizza). Termogramas plantares do pé com padrão de borboleta ligeiramente desviado foram rotulados como leves por especialistas médicos. O segundo conjunto de termogramas plantares do pé, onde havia uma distribuição anormal e de alta temperatura, foi rotulado como moderado pelos especialistas médicos, pois as distribuições de temperatura ainda não eram muito

inicia a possibilidade de desenvolvimento de úlcera no futuro próximo. Os termogramas do pé Te tir set o pantar apresentavam temperatura extremamente alta (que geralmente é indicada pela distribuição de cor vermelha nos termogramas) em todo o pé, indicando a possibilidade de desenvolvimento de úlcera no futuro imediato, e foram rotulados como graves. Tal agrupamento não foi encontrado na classificação original usando o método baseado em TCI (ou seja, classe um – classe cinco). O algoritmo de agrupamento separou as imagens em três agrupamentos. A classe leve teve 82 imagens, a classe moderada teve 84, e a classe grave teve 78 imagens.




Figura 8. Termogramas do diabético classificados em três gravidades: leve, moderada e grave.

O resultado do agrupamento k-mean pode ser melhor compreendido com a ajuda dos gráficos de pizza da Figura 9, que mostram a distribuição das classes nos diferentes clusters encontrados pela abordagem de agrupamento k-mean. Pode-se ver claramente que muitos termogramas de classe um eram muito semelhantes ao termograma de classe cinco (consulte a classe severa no gráfico circular) e muitos termogramas de classe três, classe quatro e classe cinco eram semelhantes à classe um e classe dois (consulte a classe suave no gráfico circular).

Figura 8. Termogramas do diabético classificados em três gravidades: leve, moderada e grave.




Figura 9. Distribuição das classes 1, 2, 3, 4 e 5 nas categorias de agrupamento K-mean - leve, moderada, e grave.

3.2. Classificação Clássica Baseada em Aprendizagem de Máquina

Uma vez que os novos conjuntos de dados rotulados foram confirmados usando a abordagem de agrupamento k-mean e verificados pelos peritos médicos, os recursos destacados dos 37 ex- e verificados pelos peritos médicos foram reduzidos para 27 recursos - NRT (classe um), NRT (classe dois), NRT (classe três), NRT (classe quatro), NRT (classe cinco), temperatura mais alta, TCI, HSE, ET, ETD, média e STD do angiossoma LPA; HSE, ET, ETD, média e STD do angiossoma LCA; HSE, ET, ETD, média e STD do angiossoma MCA; SMS, ETD e DST de

Figura 9. Distribuição das classes 1, 2, 3, 4 e 5 nas categorias de agrupamento K-mean - leve, moderada, e grave.

completo. Os recursos destacados em aprendizagem de máquina são recursos e após a remoção do

recursos altamente correlacionados são mostrados na Figura Suplementar S1.

e verificados pelos especialistas médicos, os recursos correlacionados destacados dos 37 ex- 3.2.1. Abordagem clássica de aprendizagem de máquina 1: combinação ideal de classificação de recursos

recursos foram reduzidos para 27 recursos - NRT (classe um), NRT (classe dois), NRT (classe três), Número de NRT (classe quatro), NRT (classe cinco), temperatura mais alta, TCI, HSE, ET, ETD, média e STD Neste experimento, 3 técnicas de seleção de recursos com 10 modelos de aprendizado de máquina

foram investigados com 27 recursos otimizados para identificar os resultados mais bem combinados em 810 investigações. A combinação com melhor desempenho é apresentada na Tabela 2. Pode ser visto que o classificador XGboost com a técnica de seleção aleatória de recursos de floresta e o os 25 principais recursos mostraram o melhor desempenho de 92,63% de pontuação F1 ponderada em diabéticos classificação de gravidade.

Tabela 2. Métricas de desempenho para as combinações de melhor desempenho usando a Abordagem 1.

Classificador	Recurso Seleção	# de Recurso	Aula	Precisão	Precisão	Sensibilidade	Pontuação F1	Especificidade	Inferência Tempo (ms)
XGBoost	Aleatório Floresta	25	Leve 92,59 ± 6,80 Moderado		91,53 ± 7,23	94,74 ± 5,80	93,1 ± 6,58	91,94 ± 7,07	0,397
			92,59 ± 6,47 Grave Geral		86,15 ± 8,53	88,89 ± 7,76	87,5 ± 8,17	93,89 ± 5,91	
				92,59 ± 4,61	96,64 ± 3,17	93,50 ± 4,34	95,04 ± 3,82	91,67 ± 4,86	
				92,59 ± 3,29	92,72 ± 3,26	92,59 ± 3,29	92,63 ± 3,28	92,31 ± 3,34	

3.2.2. Abordagem clássica 2 de aprendizado de máquina: classificação baseada em empilhamento

Como afirmado anteriormente, selecionamos os principais recursos contribuintes dos 29 projetos finalizados. recursos após uma redução de recursos. A seleção foi realizada com base na descoberta do recursos que foram categorizados como altamente correlacionados com a saída com base em todos os técnicas – Pearson, Qui-quadrado, RFE, logística, floresta aleatória e LightGBM. Tabela 3 apresenta os recursos que tinham um total de mais de quatro, e constatou-se que apenas oito características (TCI, NRT (classe quatro), NRT (classe três), a média de MPA, média de LPA, ET do LPA, média do LCA e temperatura mais alta) foram as características mais bem classificadas por todos os técnicas (Pearson, Chi-Square, RFE, logística, floresta aleatória e LightGBM). Esses oito recursos foram usados para verificar o desempenho usando diferentes classificadores de aprendizado de máquina e empilhamento realizado nos três primeiros classificadores, proporcionando o melhor resultado, como pode ser visto na Tabela 4. O classificador de empilhamento criado usando o classificador de aumento de gradiente treinado, classificador XGBoost e classificador de floresta aleatório foi o classificador de melhor desempenho, com 94,47%, 94,45%, 94,47%, 94,43% e 93,25% para exatidão, precisão, sensibilidade, pontuação F1, e especificidade, respectivamente. O desempenho desta abordagem foi melhor que a Abordagem 1, conforme mostra a Tabela 2, com diferença apenas no tempo de inferência, que foi encontrado mais no classificador de empilhamento, conforme esperado.

Tabela 3. Recursos selecionados com base nas seis técnicas de classificação de recursos.

Recurso	Pearson	Qui-Quadrado	RFE	Logística	Luz Florestal AleatóriaGBM	Total
TCI	✓	✓	✓	✓	✓	6
NRT (Classe 4)	✓	✓	✓	✓	✓	6
NRT (Classe 3)	✓	✓	✓	✓	✓	6
Média de MPA	✓	✓	✓	✓	✓	6
Média de LPA	✓	✓	✓	✓	✓	6
ET da LPA	✓	✓	✓	✓	✓	6
Média de LCA	✓	✓	✓	✓	✓	6
Temperatura mais alta	✓	✓	✓	✓	✓	6
NRT (Classe 2)	✓	✓	✓	✓		5
NRT (Classe 1)	✓	✓	✓	✓		5
TE da LCA	✓	✓	✓	✓		5
NRT (Classe 5)	✓	✓		✓		4
DST do MPA	✓	✓	✓	✓		4
ETD do MPA		✓	✓	✓	✓	4
DST da MCA	✓	✓	✓	✓		4
ETD da MCA	✓	✓		✓	✓	4
DST de LPA	✓		✓	✓		4
SMS da LCA			✓	✓	✓	4
ETD de pé inteiro		✓	✓		✓	4

Tabela 4. Métricas de desempenho por classe para os três principais classificadores de aprendizado de máquina e os classificadores empilhados classificador.

Classificador	Aula	Precisão	Precisão	Sensibilidade	Pontuação F1	Especificidade	Inferência Tempo (ms)
Aumento de gradiente	Leve	92,01 ± 4,98	91,38 ± 5,15	92,98 ± 4,69	92,17 ± 4,93	91,71 ± 5,06	0,379
	Moderado	92,01 ± 4,73	84,50 ± 6,32	86,51 ± 5,97	85,49 ± 6,15	93,92 ± 4,17	
	Forte	92,01 ± 3,37	96,30 ± 2,35	94,35 ± 2,87	95,32 ± 2,63	89,58 ± 3,80	
	Geral	92,01 ± 3,40	92,10 ± 3,38	92,01 ± 3,40	92,04 ± 3,40	91,20 ± 3,55	
XGBoost	Leve	93,24 ± 4,61	Moderado 90,08 ± 5,49	95,61 ± 3,76	92,77 ± 4,76	92,51 ± 4,83	0,336
	93,24 ± 4,38	Grave 93,24 ± 3,13	89,26 ± 5,41	85,71 ± 6,11	87,45 ± 5,78	95,86 ± 3,48	
	Geral 93,24 ± 3,15		96,75 ± 2,21	95,97 ± 2,45	96,36 ± 2,33	90,42 ± 3,66	
			93,26 ± 3,15	93,24 ± 3,15	93,22 ± 3,15	92,31 ± 3,34	
Floresta Aleatória	Leve	91,80 ± 5,04	89,19 ± 5,7	86,84 ± 6,21	88,00 ± 5,97	93,32 ± 4,58	0,327
	Moderado	91,80 ± 4,79	90,43 ± 5,14	82,54 ± 6,63	86,31 ± 6,00	95,03 ± 3,80	
	Forte	91,80 ± 3,41	93,51 ± 3,07	98,79 ± 1,36	96,08 ± 2,42	84,58 ± 4,49	
	Geral	91,80 ± 3,44	91,71 ± 3,46	91,80 ± 3,44	91,67 ± 3,47	89,32 ± 3,88	
Empilhamento (Aumento de gradiente + XGBoost+ Floresta Aleatória)	Leve	94,47 ± 4,20	Moderado 91,53 ± 5,11	94,74 ± 4,10	93,10 ± 4,65	94,39 ± 4,23	0,379 + 0,336 + 0,327 = 1.042
	94,47 ± 3,99		92,44 ± 4,62	87,30 ± 5,81	89,80 ± 5,29	96,96 ± 3,00	
	Forte	94,47 ± 2,85	96,81 ± 2,19	97,98 ± 1,75	97,39 ± 1,98	90,83 ± 3,59	
	Geral	94,47 ± 2,87	94,45 ± 2,87	94,47 ± 2,87	94,43 ± 2,88	93,25 ± 3,15	

3.3. Classificação bidimensional baseada em CNN

Conforme discutido anteriormente, os autores investigaram a aprendizagem por transferência de última geração redes - ResNet18, ResNet50, VGG19, DenseNet201, InceptionV3 e MobileNetv2, junto com técnicas populares de aprimoramento de imagem. A rede com melhor desempenho e tipos de realce (por exemplo, AHE) foram usados para classificação de gravidade. A correção gama fez não melhorou o desempenho, pois não ajudou a aprimorar os diferenciais. Uma discussão mais aprofundada sobre as técnicas de aprimoramento de imagem foi fornecida na Discussão seção. Imagens independentes de pés foram usadas para verificar se as diferentes redes pré-treinadas poderia classificá-los em diferentes níveis de gravidade. A Tabela 5 relata o AHE com melhor desempenho, com VGG19 apresentando o melhor desempenho. Deve-se notar que o melhor desempenho veio com a compensação de um tempo de inferência ligeiramente maior. O aumento na inferência O tempo para classificar a imagem do termograma foi causado pela adição da técnica de aprimoramento de imagem como etapa de pré-processamento. No entanto, o aumento no tempo de inferência devido para esta etapa adicional de pré-processamento foi de apenas 1 ms, o que não afetaria nem mesmo o tempo real aplicações de classificação. É mais importante ter um melhor desempenho do que ter uma resposta mais rápida. Em nosso estudo, o aprimoramento de imagem auxiliou no desempenho com um atraso excessivo de 1 ms. As curvas ROC para os termogramas original e AHE também são mostrado na Figura 10.

Tabela 5. Desempenho do teste quádruplo CNN bidimensional do classificador de gravidade.

Rede de Aprimoramento	Aula	Precisão	Precisão	Sensibilidade	Pontuação F1	Especificidade	Inferência Tempo (ms)
Original VGG 19	Leve	98,77 ± 2,86	98,21 ± 3,44	96,49 ± 4,78	97,34 ± 4,18	99,47 ± 1,88	7.271
	Moderado	94,67 ± 5,55	86,76 ± 8,37	93,65 ± 6,02	90,07 ± 7,39	95,03 ± 5,37	
	Forte	95,90 ± 3,49	97,50 ± 2,75	94,35 ± 4,06	95,90 ± 3,49	97,5 ± 2,75	
	Geral	94,76 ± 2,82	94,89 ± 2,76	94,67 ± 2,82	94,73 ± 2,80	97,32 ± 2,03	
AHE VGG 19	Leve	98,77 ± 2,86	96,55 ± 4,74	98,25 ± 3,4	97,39 ± 4,14	98,93 ± 2,67	8.161
	Moderado	95,08 ± 5,34	90,48 ± 7,25	90,48 ± 7,25	90,48 ± 7,25	96,69 ± 4,42	
	Forte	96,31 ± 3,32	96,75 ± 3,12	95,97 ± 3,46	96,36 ± 3,3	96,67 ± 3,16	
	Geral	95,08 ± 2,71	95,08 ± 2,71	95,09 ± 2,71	95,08 ± 2,71	97,2 ± 2,07	
Gama Correção VGG 19	Leve	88,11 ± 8,40	90,91 ± 7,46	87,72 ± 8,52	89,29 ± 8,03	88,24 ± 8,36	9.651
	Moderado	88,11 ± 7,99	75,71 ± 10,59	84,13 ± 9,02	79,70 ± 9,93	89,50 ± 7,57	
	Forte	88,11 ± 5,70	94,12 ± 4,14	90,32 ± 5,20	92,18 ± 4,73	85,83 ± 6,14	
	Geral	88,11 ± 4,06	88,62 ± 3,99	88,11 ± 4,06	88,28 ± 4,04	87,34 ± 4,17	

	Forte	96,31±3,32	96,75±3,12	95,97±3,46	96,36±3,3	96,67±3,16	
	Geral	95,08±2,71	95,08±2,71	95,09±2,71	95,08±2,71	97,2±2,07	
	Leve	88,11±8,40	90,91±7,46	87,72±8,52	89,29±8,03	88,24±8,36	
	Moderado	88,11±7,99	75,71±10,59	84,13±9,02	79,70±9,93	89,50±7,57	
Sensores 2022, 22, 4249	Forte	88,11±5,70	94,12±4,14	90,32±5,20	92,18±4,73	85,83±6,14	9.651 de 23
	Geral	88,11±4,06	88,62±3,99	88,11±4,06	88,28±4,04	87,34±4,17	

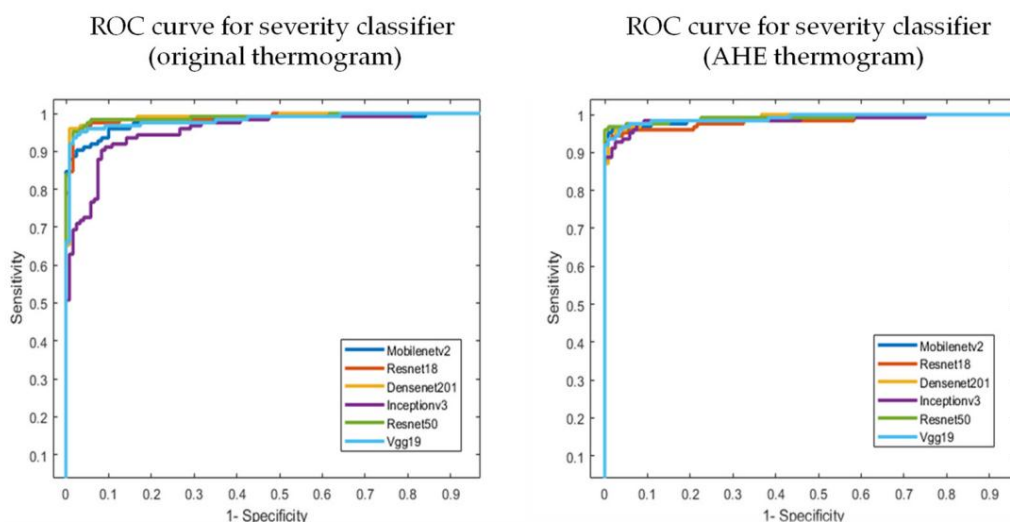


Figura 10. AUC para o termograma AHE original e de melhor desempenho na classificação de gravidade.

4. Discussão

Como mencionado anteriormente, os autores conduziram uma extensa investigação e desenvolveram um classificador AdaBoost treinado para atingir uma pontuação F1 de 97% na classificação de diabéticos e pacientes saudáveis usando imagens de termograma [37]. A rede de termogramas do pé diabético (DFTNet) propôs uma técnica de aprendizagem profunda para classificar as imagens do banco de dados de termogramas plantares em um esquema de classificação não conveniente, onde os resultados foram mostrados fazendo duas aulas por vez e calculando a média dos resultados após dez dobras de um valor diferente combinação de duas classes de conjuntos [38]. Como discutido anteriormente, a classificação da verdade básica de pacientes neste banco de dados foi realizada usando o escore TCI e baseou-se inteiramente no confiabilidade da técnica de pontuação TCI. Trabalhos anteriores e a falta de classificação de gravidade dos complicações do pé diabético motivaram este trabalho.

Novamente, até onde é do conhecimento do autor, nenhum estudo anterior investigou técnicas de aprimoramento de imagem para classificação da gravidade do pé diabético usando termogramas para CNNs 2D. Os autores investigaram diferentes redes pré-treinadas e também descobriram que as técnicas de aprimoramento de imagem auxiliaram no desempenho da classificação. Figura 11 confirma o melhor desempenho da técnica de aprimoramento de imagem usando a pontuação F1 métrica de desempenho.

Mesmo a abordagem clássica de aprendizado de máquina proporcionou melhor desempenho de classificação usando TCI, NRT (Classe 4), NRT (Classe 3), média de MPA, média de LPA, ET de LPA, média de LCA e características extraídas de temperatura mais alta do termograma. Os classificadores empilhados usando gradiente boost popular, XGBoost e classificadores aleatórios de floresta forneceram um desempenho de classificação comparável com um tempo de inferência muito menor (Tabelas 4 e 5). Os seguintes resultados interessantes podem ser resumidos:

O AHE, devido à sua equalização especial, auxiliou na classificação da gravidade utilizando o rede VGG 19 pré-treinada.

Uma rede de camada mais profunda como a Densenet201 não melhorou o desempenho para aprimoramento de imagem, o que pode ser atribuído à natureza simplista do termograma imagens, que não exigiam uma rede muito profunda para extrair recursos significativos.

Os recursos propostos [37] e a nova técnica de classificação ajudaram na classificação do termogramas diabéticos em diferentes grupos de gravidade.

métrica de desempenho de pontuação.




Figura 11. Comparação da pontuação F1 entre imagens de termograma originais e aprimoradas por AHE usando o classificador de gravidade 2D.

5. Conclusões

Os problemas do pé diabético são um problema que tem grandes consequências não só em termos de mortalidade, mas também em termos das despesas necessárias para monitorizar e controlar a doença. Assim, a detecção precoce e a classificação da gravidade podem auxiliar na prevenção de tais complicações. A implantação do aprendizado de máquina em aplicações biomédicas poderia ajudar na preparação de soluções fáceis de usar para detecção precoce, não apenas para especialistas médicos economizarem seu tempo, mas também porque tais soluções podem ser úteis para pacientes em ambiente domiciliar. Eles podem usá-lo em suas casas, especialmente em tempos de pandemia, onde as visitas aos serviços de saúde são preferiu ser limitado, evitando pressão sobre o sistema de saúde. Os autores do artigo propuseram uma nova estrutura para agrupar termogramas diabéticos com base na gravidade, que não estava presente na literatura e os que estavam disponíveis necessitavam de verificação. O CNN 2D treinado e modelos clássicos de aprendizado de máquina podem ajudar na estratificação de gravidade usando termogramas de pés, que podem ser capturados por câmeras infravermelhas (IR). Para o melhor de De acordo com o conhecimento do autor, este foi o primeiro estudo analisando tal condição de pé diabético classificador de gravidade para estratificação precoce e confiável do pé diabético. A máquina o desempenho do classificador de aprendizagem foi comparável ao desempenho da CNN 2D usando imagem Aprimoramento. Concluindo, tal sistema poderia ser facilmente implantado como uma aplicação web, e os pacientes poderiam se beneficiar de cuidados de saúde remotos usando apenas uma câmera infravermelha e um aplicativo móvel, que é uma direção futura de nossa pesquisa.

Materiais Suplementares: As seguintes informações de apoio podem ser baixadas em <https://www.mdpi.com/article/10.3390/s22114249/s1>: Figura S1: mapa de calor da matriz de correlação com todos os recursos (A) e após a remoção dos recursos altamente correlacionados (B).

Contribuições dos Autores: Análise formal, AK, MEHC, MBIR, SHMA, MAA e AAAB; Investigação, AK, MEHC, SK, AAAB e AH; Metodologia, AK, MEHC, SK, AAAB e AH; Recursos, SK, TR e MHC; Software, TR, MHC e MAA; Supervisão, MBIR, SHMA e AAAB; Validação, RA e RAM; Visualização, RAM; Redação – rascunho original, AK; Redação – revisão e edição, MBIR, SHMA, MAA, RA, RAM e AH Todos os autores leram e concordaram com a versão publicada do manuscrito.

Financiamento: Este trabalho foi viabilizado pelo Fundo Nacional de Pesquisa do Qatar (QNRF) NPRP12S- 0227-190164 e pelo Co-Fundo de Colaboração de Pesquisa Internacional (IRCC) com bolsa IRCC-2021-001 e Universiti Kebangsaan Malaysia sob a bolsa DPK-2021-001. As declarações aqui feitas são de exclusiva responsabilidade dos autores.

Declaração do Conselho de Revisão Institucional: Não aplicável.

Termo de Consentimento Livre e Esclarecido: Não aplicável.

Declaração de disponibilidade de dados: Não aplicável.

Conflitos de interesse: Os autores declaram não haver conflito de interesses.

Referências

- Cho, N.; Kirigia, J.; Mbanya, J.; Ogurustova, K.; Guariguatá, L.; Rathmann, W. IDF Diabetes Atlas, 8ª ed.; Diabetes Internacional Federação: Bruxelas, Bélgica, 2015; pág. 160.
- Sims, DS Jr.; Cavanagh, PR; Ulbrecht, JS Fatores de risco no pé diabético: Reconhecimento e manejo. *Física. Lá.* **1988**, *68*, 1887–1902. [\[RefCruz\]](#) [\[Pub Med\]](#)
- Iversen, MM; Diga, GS; Riise, T.; Hanestad, BR; Adeus, T.; Graue, M.; Midthjell, K. História de úlcera no pé aumenta a mortalidade entre indivíduos com diabetes: Acompanhamento de dez anos do Nord-Trøndelag Health Study, Noruega. *Cuidados com Diabetes* **2009**, *32*, 2193–2199. [\[RefCruz\]](#) [\[Pub Med\]](#)
- Singh, G.; Chawla, S. Amputação em pacientes diabéticos. *Med. J. Forças Armadas da Índia* **2006**, *62*, 36–39. [\[RefCruz\]](#)
- Armstrong, DG; Boulton, AJ; Bus, SA Úlceras do pé diabético e sua recorrência. *N. Engl. J. Med.* **2017**, *376*, 2367–2375. [\[RefCruz\]](#)
- Ponirakis, G.; Elhadd, T.; Chinnaiyan, S.; Dabbous, Z.; Siddiqui, M.; Al-muhammad, H.; Petropoulos, IN; Khan, A.; Ashawesh, KA; Dukhan, KMO Prevalência e manejo da neuropatia diabética na atenção secundária no Qatar. *Diabetes/Metab. Res. Rev.* **2020**, *36*, e3286. [\[RefCruz\]](#)
- Ananian, CE; Dhillion, YS; Van Gils, CC; Lindsey, DC; Otto, RJ; Pomba, CR; Pierce, JT; Saunders, MC Um ensaio multicêntrico, randomizado e simples-cego comparando a eficácia da membrana placentária criopreservada viável com o substituto dérmico derivado de fibroblastos humanos para o tratamento de úlceras crônicas do pé diabético. *Regeneração de reparo de feridas.* **2018**, *26*, 274–283. [\[RefCruz\]](#)
- Peter-Riesch, B. O pé diabético: o desafio sem fim. *Novembro de Diabetes* **2016**, *31*, 108–134.
- Ladyzynski, P.; Foltynski, P.; Molik, M.; Tarwacka, J.; Migalska-Musial, K.; Mlynarczuk, M.; Wojcicki, JM; Krzymien, J.; Karnafel, W. Área de úlceras diabéticas estimada aplicando um sistema de teleassistência domiciliar baseado em scanner de pés e três métodos de referência. *Tecnologia em Diabetes. Lá.* **2011**, *13*, 1101–1107. [\[RefCruz\]](#)
- Bluedrop Médico. Disponível on-line: <https://bluedropmedical.com/> (acessado em 1 de abril de 2022).
- Sugama, J.; Matsui, Y.; Sanada, H.; Konya, C.; Okuwa, M.; Kitagawa, A. Um estudo da eficiência e conveniência de um avançado sistema portátil de medição de feridas (VISITRAKTM). *J. Clin. Enfermeira.* **2007**, *16*, 1265–1269. [\[RefCruz\]](#)
- Molik, M.; Foltynski, P.; Ladyzynski, P.; Tarwacka, J.; Migalska-Musial, K.; Ciechanowska, A.; Sabalinska, S.; Mlynarczuk, M.; Wojcicki, JM; Krzymien, J. Comparação dos métodos de avaliação da área da ferida na síndrome do pé diabético. *Biocibernet. Biomédica. Eng.* **2010**, *30*, 3–15.
- Reyzelman, AM; Koelewyn, K.; Murphy, M.; Shen, X.; Yu, E.; Pilai, R.; Fu, J.; Scholten, HJ; Ma, R. Meias de monitoramento contínuo de temperatura para uso doméstico em pacientes com diabetes: Estudo observacional. *J. Med. Res. Internet.* **2018**, *20*, e12460. [\[RefCruz\]](#) [\[Pub Med\]](#)
- Frykberg, RG; Gordon, Illinois; Reyzelman, AM; Cazzell, SM; Fitzgerald, RH; Rothenberg, GM; Bloom, JD; Petersen, BJ; Linders, DR; Nouvong, A. Viabilidade e eficácia de uma tecnologia de tapete inteligente para prever o desenvolvimento de úlceras plantares diabéticas. *Cuidados com Diabetes* **2017**, *40*, 973–980. [\[RefCruz\]](#) [\[Pub Med\]](#)
- Nagase Inagaki, FN O Impacto dos Problemas do Pé Diabético na Qualidade de Vida Relacionada à Saúde das Pessoas com Diabetes. Dissertação de mestrado, Universidade de Alberta, Edmonton, AB, Canadá, 2017. 16. van Doremalen, RF; van Netten, JJ; van Baal, JG; Vollenbroek-Hutten, MM; van der Heijden, F. Termografia infravermelha 3D para detecção de inflamação na doença do pé diabético: uma prova de conceito. *J. Diabetes Ciência. Tecnologia.* **2020**, *14*, 46–54. [\[RefCruz\]](#)

17. Crisologo, PA; Lavery, LA Monitoramento remoto domiciliar para identificar e prevenir ulcerações no pé diabético. *Ana. Trad. Med.* **2017**, *5*, 430. [\[RefCruz\]](#)
18. Yang, J.; Yin, P.; Zhou, M.; Ou, C.-Q.; Li, M.; Liu, Y.; Gao, J.; Chen, B.; Liu, J.; Bai, L. O efeito da temperatura ambiente no diabetes mortalidade na China: um estudo de série temporal em várias cidades. *Ciência. Meio Ambiente Total.* **2016**, *543*, 75–82. [\[RefCruz\]](#)
19. Canção, X.; Jiang, L.; Zhang, D.; Wang, X.; Poderia.; Hu, Y.; Tang, J.; Li, X.; Huang, W.; Meng, Y. Impacto da exposição de curto prazo a temperaturas extremas na morbidade e mortalidade do diabetes mellitus? Uma revisão sistemática e meta-análise. *Meio Ambiente. Ciência. Poluição. Res.* **2021**, *28*, 58035–58049. [\[RefCruz\]](#)
20. Foltýnski, P.; Mrozkiewicz-Rakowska, B.; Źadyński, P.; Wójcicki, JM; Karnafel, W. A influência da temperatura ambiente na temperatura do pé em pacientes com ulceração do pé diabético. *Biociberna. Biomédica. Eng.* **2014**, *34*, 178–183. [\[RefCruz\]](#)
21. Alberts, JW; Jacobson, R. Cirurgia nervosa de descompressão para neuropatia diabética: Uma revisão estruturada de ensaios clínicos publicados. *Diabetes Metab. Sindr. Obesos. Alvos lá.* **2018**, *11*, 493. [\[CrossRef\]](#)
22. Hernández-Contreras, D.; Peregrina-Barreto, H.; Rangel-Magdaleno, J.; Gonzalez-Bernal, J. Revisão narrativa: Pé diabético e termografia infravermelha. *Física infravermelha. Tecnologia.* **2016**, *78*, 105–117. [\[RefCruz\]](#)
23. Ring, F. Imagens térmicas hoje e sua relevância para o diabetes. *J. Diabetes Ciência. Tecnologia.* **2010**, *4*, 857–862. [\[RefCruz\]](#) [\[Pub Med\]](#)
24. Chan, AW; MacFarlane, IA; Bowsher, DR Termografia de contato do pé neuropático diabético doloroso. *Cuidados com o Diabetes* **1991**, *14*, 918–922. [\[RefCruz\]](#) [\[Pub Med\]](#)
25. Nagase, T.; Sanada, H.; Takehara, K.; Oe, M.; Iizaka, S.; Ohashi, Y.; Obá, M.; Kadowaki, T.; Nakagami, G. Variações dos padrões termográficos plantares em controles normais e pacientes diabéticos sem úlcera: nova classificação usando o conceito de angiossoma. *J. Plast. Reconstrução Cirurgia Estética.* **2011**, *64*, 860–866. [\[RefCruz\]](#) [\[Pub Med\]](#)
26. Mori, T.; Nagase, T.; Takehara, K.; Oe, M.; Ohashi, Y.; Amemiya, A.; Noguchi, H.; Ueki, K.; Kadowaki, T.; Sanada, H. Sistema de classificação de padrões morfológicos para termografia plantar de pacientes com diabetes; Publicações SAGE Sage CA: Los Angeles, CA, EUA, 2013.
27. Jones, BF Uma reavaliação do uso da análise de imagens térmicas infravermelhas na medicina. *IEEE Trans. Med. Imagens* **1998**, *17*, 1019–1027. [\[RefCruz\]](#) [\[Pub Med\]](#)
28. Kaabouch, N.; Chen, Y.; Anderson, J.; Ames, F.; Paulson, R. Análise de assimetria baseada em algoritmos genéticos para a previsão de úlceras nos pés. Em *Visualização e Análise de Dados 2009*; Sociedade Internacional de Óptica e Fotônica: Bellingham, WA, EUA, 2009; pág. 724304.
29. Kaabouch, N.; Chen, Y.; Hu, W.-C.; Anderson, JW; Ames, F.; Paulson, R. Aprimoramento da sobreposição baseada em assimetria análise por meio de extração de recursos. *J. Eletrôn. Imagens* **2011**, *20*, 013012. [\[CrossRef\]](#)
30. Liu, C.; van Netten, JJ; Van Baal, JG; Autocarro, SA; van Der Heijden, F. Detecção automática de complicações do pé diabético com termografia infravermelha por análise assimétrica. *J. Biomédica. Optar.* **2015**, *20*, 026003. [\[CrossRef\]](#)
31. Hernández-Contreras, D.; Peregrina-Barreto, H.; Rangel-Magdaleno, J.; Ramírez-Cortes, J.; Renero-Carrillo, F. Classificação automática de padrões térmicos em pé diabético com base no espectro de padrões morfológicos. *Física infravermelha. Tecnologia.* **2015**, *73*, 149–157. [\[RefCruz\]](#)
32. Hernández-Contreras, D.; Peregrina-Barreto, H.; Rangel-Magdaleno, J.; González-Bernal, J.; Altamirano-Robles, L. Um índice quantitativo para classificação das alterações térmicas plantares no pé diabético. *Física infravermelha. Tecnologia.* **2017**, *81*, 242–249. [\[RefCruz\]](#)
33. Hernández-Contreras, DA; Peregrina-Barreto, H.; Rangel-Magdaleno, JDJ; Orihuela-Espina, F. Aproximação estatística da distribuição da temperatura plantar em indivíduos diabéticos com base no modelo de mistura beta. *Acesso IEEE* **2019**, *7*, 28383–28391. [\[RefCruz\]](#)
34. Kamavisdar, P.; Saluja, S.; Agrawal, S. Uma pesquisa sobre abordagens e técnicas de classificação de imagens. *Interno. J. Adv. Res. Computação. Comum. Eng.* **2013**, *2*, 1005–1009.
35. Ren, J. ANN vs. SVM: Qual deles tem melhor desempenho na classificação de MCCs em imagens de mamografia. *Sistema baseado em conhecimento.* **2012**, *26*, 144–153. [\[RefCruz\]](#)
36. Lu, D.; Weng, Q. Um levantamento de métodos e técnicas de classificação de imagens para melhorar o desempenho da classificação. *Interno. J. Remoto Sens.* **2007**, *28*, 823–870. [\[RefCruz\]](#)
37. Khandakar, A.; Chowdhury, ME; Reaz, MBI; Ali, SHM; Hasan, MA; Kiranyaz, S.; Rahman, T.; Alfkey, R.; Bakar, AAA; Malik, RA Um modelo de aprendizado de máquina para detecção precoce de pé diabético usando imagens de termograma. *Computação. Biol. Med.* **2021**, *137*, 104838. [\[CrossRef\]](#) [\[Pub Med\]](#)
38. Cruz-Vega, I.; Hernández-Contreras, D.; Peregrina-Barreto, H.; Rangel-Magdaleno, JdJ; Ramirez-Cortes, JM Classificação de aprendizado profundo para termogramas de pés diabéticos. *Sensores* **2020**, *20*, 1762. [\[CrossRef\]](#)
39. Hernández-Contreras, DA; Peregrina-Barreto, H.; de Jesus Rangel-Magdaleno, J.; Renero-Carrillo, FJ Termograma plantar banco de dados para estudo de complicações do pé diabético. *Acesso IEEE* **2019**, *7*, 161296–161307. [\[RefCruz\]](#)
40. Maldonado, H.; Bayareh, R.; Torres, I.; Vera, A.; Gutierrez, J.; Leija, L. Detecção automática de zonas de risco na planta do pé diabético por meio do processamento de imagens termográficas obtidas em ambiente não controlado. *Física infravermelha. Tecnologia.* **2020**, *105*, 103187. [\[Ref Cruzada\]](#)
41. Saminathan, J.; Sasikala, M.; Narayanamurthy, V.; Rajesh, K.; Arvind, R. Detecção auxiliada por computador de úlcera de pé diabético usando análise de assimetria de características de textura e temperatura. *Física infravermelha. Tecnologia.* **2020**, *105*, 103219. [\[Ref Cruzada\]](#)
42. Adam, M.; Ng, EY; Ah, SL; Heng, ML; Hagiwara, Y.; Tan, JH; Tong, JW; Acharya, UR Detecção automatizada de pé diabético com e sem neuropatia usando transformação wavelet de complexo de árvore dupla de dupla densidade em termogramas de pé. *Física infravermelha. Tecnologia.* **2018**, *92*, 270–279. [\[RefCruz\]](#)

43. Adam, M.; Ng, EY; Ah, SL; Heng, ML; Hagiwara, Y.; Tan, JH; Tong, JW; Acharya, UR Caracterização automatizada do pé diabético utilizando características não lineares extraídas de termogramas. Física infravermelha. Tecnologia. **2018**, *89*, 325–337. [\[RefCruz\]](#)
44. Gururajaráo, SB; Venkatappa, U.; Shivaram, JM; Sikkandar, MEU; Al Amoudi, A. Termografia infravermelha e computação suave para avaliação do pé diabético. Em *Aprendizado de Máquina em Análise de Bio-Sinais e Diagnóstico por Imagem*; Elsevier: Amsterdã, Holanda, 2019; pp. 73–97.
45. Etehadtavakol, M.; Emrani, Z.; Ng, EYK Extração rápida das regiões mais quentes ou mais frias de imagens termográficas médicas. *Med. Biol. Eng. Computação*. **2019**, *57*, 379–388. [\[RefCruz\]](#)
46. Wang, Y.; Huang, R.; Huang, G.; Canção, S.; Wu, C. Aprendizagem colaborativa com rótulos corrompidos. *Rede Neural*. **2020**, *125*, 205–213. [\[RefCruz\]](#) [\[Pub Med\]](#)
47. Aradillas, JC; Murillo-Fuentes, JJ; Olmos, PM Melhorando o HTR offline em pequenos conjuntos de dados eliminando rótulos não confiáveis. Em *Anais da 17ª Conferência Internacional sobre Fronteiras no Reconhecimento de Caligrafia (ICFHR) de 2020*, Dortmund, Alemanha, 8–10 de setembro de 2020; páginas 25–30.
48. Hu, W.; Huang, Y.; Zhang, F.; Li, R. Paradigma de tolerância a ruído para treinamento de CNNs de reconhecimento facial. Em *Anais da Conferência IEEE/CVF sobre Visão Computacional e Reconhecimento de Padrões*, Long Beach, CA, EUA, 15–20 de junho de 2019; pp.
49. Ding, Y.; Wang, L.; Ventilador, D.; Gong, B. Uma abordagem semissupervisionada em dois estágios para aprender com rótulos barulhentos. Em *Anais da Conferência de Inverno IEEE 2018 sobre Aplicações de Visão Computacional (WACV)*, Lake Tahoe, NV, EUA, 12–15 de março de 2018; pp.
50. Fraiwan, L.; AlKhadari, M.; Ninan, J.; Mustafá, B.; Saleh, A.; Ghazal, M. Sistema móvel de detecção de úlcera no pé diabético usando inteligente câmera térmica do telefone: um estudo de viabilidade. *Biomédica. Eng. On-line* **2017**, *16*, 117. [\[CrossRef\]](#)
51. Alzubaidi, L.; Fadhel, MA; Olewi, SR; Al-Shamma, O.; Zhang, J. DPU_QUTNet: Classificação de úlcera de pé diabético usando romance rede neural convolucional profunda. *Multimed. Ferramentas Appl.* **2020**, *79*, 15655–15677. [\[RefCruz\]](#)
52. Tulloch, J.; Zamani, R.; Akrami, M. Aprendizado de máquina na prevenção, diagnóstico e tratamento de úlceras de pé diabético: A revisão sistemática. *Acesso IEEE* **2020**, *8*, 198977–199000. [\[RefCruz\]](#)
53. Yadav, J.; Sharma, M. Uma revisão do algoritmo K-mean. *Interno. J. Eng. Tendências Tecnológicas*. **2013**, *4*, 2972–2976.
54. Taylor, GI; Palmer, JH Teoria do angiossoma. *Ir. J. Plast. Surg.* **1992**, *45*, 327–328. [\[RefCruz\]](#)
55. Xie, X. Análise de componentes principais. 2019. Disponível on-line: https://www.google.com/url?sa=t&rct=j&q=&esrc=s&source=web&cd=&ved=2ahUKEwi25YTAgt3AhUGmlYBHdtqDwYQFnoECAMQAAQ&url=https%3A%2F%2Fwww.ics.uci.edu%2F~{jxhx}%2Fcourses%2FCS273P%2F12-pca-273p.pdf&usq=AOvVaw1xc-ulUHscvWmCWGL411_ (acessado em 1 de agosto de 2021).
56. Queras. Disponível on-line: <https://keras.io/> (acessado em 1 de agosto de 2021).
57. Russakovsky, O.; Deng, J.; Su, H.; Krause, J.; Satheesh, S.; Maé, S.; Huang, Z.; Karpatia, A.; Khosla, A.; Bernstein, M. Imagenet desafio de reconhecimento visual em grande escala. *Interno. J. Computação. Vis.* **2015**, *115*, 211–252. [\[RefCruz\]](#)
58. Simonyan, K.; Zisserman, A. Redes convolucionais muito profundas para reconhecimento de imagens em grande escala. *arXiv* **2014**, arXiv:1409.1556.
59. Cohn, R.; Holm, E. Aprendizado de máquina não supervisionado por meio de aprendizado de transferência e agrupamento k-means para classificar dados de imagem de materiais. *Integr. Matéria. Fabrico. Inovar.* **2021**, *10*, 231–244. [\[RefCruz\]](#)
60. Canção, K.; Yan, Y. Um método robusto de ruído baseado em padrões binários locais completos para defeitos superficiais de tiras de aço laminadas a quente. *Apl. Surf. Ciênc.* **2013**, *285*, 858–864. [\[RefCruz\]](#)
61. Blankenship, SM; Campbell, Sr.; Hess, JE; Hess, MA; Kassler, TW; Kozfkay, CC; Matala, AP; Narum, SR; Paquin, MM; Pequenas linhagens e metapopulações MP principais no Rio Columbia *Oncorhynchus mykiss* são estruturadas por características e ambientes dinâmicos da paisagem. *Trad. Sou. Peixe. Soc.* **2011**, *140*, 665–684. [\[RefCruz\]](#)
62. Hamed, MAR Aplicação de modelos de classificação de qualidade de águas superficiais usando análise de componentes PRINCIPAIS e cluster Análise. 2019. Disponível online: <https://ssrn.com/abstract=3364401> (acessado em 1 de agosto de 2021).
63. Malik, H.; Hemati, H.; Hassan, AE Detecção automática de desvios de desempenho em testes de carga de sistemas de grande escala. Em *Anais da 35ª Conferência Internacional sobre Engenharia de Software (ICSE) de 2013*, São Francisco, CA, EUA, 18–26 de maio de 2013; páginas 1012–1021.
64. Dedo do pé, MT; Kanzaki, M.; Lien, T.-H.; Cheng, K.-S. Padrões de precipitação espacial e temporal na Zona Seca Central, Mianmar-A análise hidrológica em escala cruzada. *Terra. Atmos. Oceano. Ciência.* **2017**, *28*, 425–436. [\[RefCruz\]](#)
65. Lloyd, S. Quantização de mínimos quadrados em PCM. *IEEE Trans. Inf. Teoria* **1982**, *28*, 129–137. [\[RefCruz\]](#)
66. Bock, H.-H. Métodos de agrupamento: uma história de algoritmos k-means. Em *Contribuições Seleccionadas em Análise e Classificação de Dados*; Springer: Berlim/Heidelberg, Alemanha, 2007; páginas 161–172.
67. Jain, AK Clustering de dados: 50 anos além do K-means. *Reconhecimento de padrões. Vamos.* **2010**, *31*, 651–666. [\[RefCruz\]](#)
68. Artur, D.; Vassilvitskii, S. k-Means++: As vantagens da semente cuidadosa; Biblioteca Digital ACM: Stanford, CA, EUA, 2006.
69. Anwar, SM; Majid, M.; Qayyum, A.; Awais, M.; Alnowami, M.; Khan, MK Análise de imagens médicas usando redes neurais convolucionais : uma revisão. *J. Med. Sist.* **2018**, *42*, 226. [\[CrossRef\]](#)
70. Tahir, AM; Qiblawey, Y.; Khandakar, A.; Rahman, T.; Khurshid, EUA; Musharavati, F.; Islã, M.; Kiranyaz, S.; Al-Maadeed, S.; Chowdhury, ME Aprendizado profundo para classificação confiável de COVID-19, MERS e SARS a partir de imagens de radiografia de tórax. *Cog. Computação.* **2022**, *1–21*. [\[RefCruz\]](#)
71. Deng, J.; Dong, W.; Socher, R.; Li, L.-J.; Li, K.; Fei-Fei, L. Imagenet: Um banco de dados de imagens hierárquicas em grande escala. Em *Anais da Conferência IEEE de 2009 sobre Visão Computacional e Reconhecimento de Padrões*, Miami, FL, EUA, 20–25 de junho de 2009; pp. 248–255.

72. Mishra, M.; Menon, H.; Mukherjee, A. Caracterização dos sons cardíacos S1 e S2 usando autoencoder empilhado e convolucional Rede neural. *IEEE Trans. Instrumento. Medidas*. **2018**, 68, 3211–3220. [RefCruz]
73. Szegedy, C.; Vanhoucke, V.; Ioffe, S.; Shlens, J.; Wojna, Z. Repensando a arquitetura inicial para visão computacional. Em *Anais da Conferência IEEE sobre Visão Computacional e Reconhecimento de Padrões*, Las Vegas, NV, EUA, 27–30 de junho de 2016; pp.
74. Sandler, M.; Howard, A.; Zhu, M.; Zhmoginov, A.; Chen, L.-C. Mobilenetv2: Resíduos invertidos e gargalos lineares. Em *Anais da Conferência IEEE sobre Visão Computacional e Reconhecimento de Padrões*, Salt Lake City, UT, EUA, 18–22 de junho de 2018; páginas 4510–4520.
75. Zimmerman, JB; Pizer, SM; Staab, EV; Perry, Jr.; McCartney, W.; Brenton, BC Uma avaliação da eficácia do adaptativo equalização de histograma para realce de contraste. *IEEE Trans. Med. Imagem* **1988**, 7, 304–312. [RefCruz]
76. Tawisfur Rahman, AK; Qiblawey, Y.; Tahir, A.; Kiranyaz, S.; Saad, MTI; Kashem, BA; Al Maadeed, S.; Zughaier, SM; Khan, MEHCMS Explorando o efeito de técnicas de aprimoramento de imagem na detecção de COVID-19 usando imagens de radiografia de tórax. *arXiv* **2020**, arXiv:2012.02238.
77. Chowdhury, MH; Shuzan, MNI; Chowdhury, ME; Mahbub, ZB; Uddin, MM; Khandakar, A.; Reaz, MBI Estimativa da pressão arterial a partir do sinal do fotopletimograma e características demográficas usando técnicas de aprendizado de máquina. *Sensores* **2020**, 20, 3127. [CrossRef]
78. Hall, MA Seleção de recursos baseada em correlação para aprendizado de máquina. Ph.D. Tese, Universidade de Waikato, Hamilton, New Zelândia, 1999.
79. Perceptron multicamadas. Disponível online: https://en.wikipedia.org/wiki/Multilayer_perceptron (acessado em 2 de março de 2022).
80. Zhang, Y. Suporte ao algoritmo de classificação de máquinas vetoriais e sua aplicação. Nos *Anais da Conferência Internacional sobre Computação da Informação e Aplicações*; Springer: Berlim/Heidelberg, Alemanha, 2012; páginas 179-186.
81. Pal, M. Classificador florestal aleatório para classificação de sensoriamento remoto. *Interno. J. Sensor Remoto*. **2005**, 26, 217–222. [RefCruz]
82. Sharaff, A.; Gupta, H. Classificador extra-árvore com abordagem metaheurística para classificação de email. Em *Avanços em Informática Ciências da Comunicação e da Computação*; Springer: Berlim/Heidelberg, Alemanha, 2019; pp. 189–197.
83. Bahad, P.; Saxena, P. Estudo de algoritmos adaboost e gradiente boosting para análise preditiva. Nos *Anais da Conferência Internacional sobre Computação Inteligente e Comunicação Inteligente 2019*; Springer: Singapura, 2020; págs. 235–244.
84. Regressão Logística. Disponível online: https://en.wikipedia.org/wiki/Logistic_regression (acessado em 2 de março de 2022).
85. Liao, Y.; Vemuri, VR Uso do classificador k-vizinho mais próximo para detecção de intrusão. *Computação. Seguro*. **2002**, 21, 439–448. [RefCruz]
86. Shi, X.; Li, Q.; Qi, Y.; Huang, T.; Li, J. Uma abordagem de previsão de acidentes baseada em XGBoost. Em *Anais da 12ª Conferência Internacional sobre Sistemas Inteligentes e Engenharia de Conhecimento (ISKE) de 2017*, Nanjing, China, 24–26 de novembro de 2017; páginas 1–7.
87. Bobkov, V.; Bobkova, A.; Porshnev, S.; Zuzin, V. A aplicação do aprendizado conjunto para delineamento do ventrículo esquerdo em registros ecocardiográficos. Em *Proceedings of the 2016 Dynamics of Systems, Mechanisms and Machines (Dynamics)*, Omsk, Rússia, 15–17 de novembro de 2016; páginas 1–5.
88. Gu, Q.; Li, Z.; Han, J. Redução de dimensionalidade discriminante linear. Nos *Anais da Conferência Europeia Conjunta sobre Aprendizado de Máquina e Descoberta de Conhecimento em Bancos de Dados*; Springer: Berlim/Heidelberg, Alemanha, 2011; pp. 549–564.
89. Chen, T.; Ele, T.; Benesty, M.; Khotilovich, V.; Tang, Y. Xgboost: reforço extremo de gradiente; Pacote R versão 0.4-2; 2015; páginas 1–4. Disponível on-line: <https://www.google.com/url?sa=t&rct=j&q=&esrc=s&source=web&cd=&cad=rja&uact=8&ved=2ahUKEwjGh7GmhNn3AhU6tIYBHRGJBQYQFnoECAMQAAQ&url=https%3A%2F%2Fcran.microsoft.com%2Fsnapshot%2F2015-10-20%2Fweb%2Fpacotes%2Fxfxgboost%2Fxfxgboost.pdf&usg=AOvVaw1w25OwKdxLEfpj0rZsvL6J> (acessado em 1 de março de 2022).
90. Saeys, Y.; Abeel, T.; Van de Peer, Y. Seleção robusta de recursos usando técnicas de seleção de recursos de conjunto. Nos *Anais da Conferência Europeia Conjunta sobre Aprendizado de Máquina e Descoberta de Conhecimento em Bancos de Dados*; Springer: Berlim/Heidelberg, Alemanha, 2008; págs. 313–325.
91. Petkovic, M.; Kocev, D.; Džeroski, S. Classificação de recursos para regressão multialvo. *Mach. Aprender*. **2020**, 109, 1179–1204. [RefCruz]
92. Yusof, AR; Udzir, NI; Selamat, A.; Hamdan, H.; Abdullah, MT Seleção de recurso adaptativo para ataque de negação de serviços (DoS). Em *Proceedings of the 2017 IEEE Conference on Application, Information and Network Security (AINS)*, Miri, Malásia, 13–14 de novembro de 2017; págs. 81–84.
93. Saidi, R.; Bouaguel, W.; Essoussi, N. Método de seleção de recursos híbridos baseado no algoritmo genético e coeficiente de correlação de Pearson. Em *Paradigmas de Aprendizado de Máquina: Teoria e Aplicação*; Springer: Berlim/Heidelberg, Alemanha, 2019; págs. 3–24.
94. Lin, X.; Yang, F.; Zhou, L.; Yin, P.; Kong, H.; Xing, W.; Luxo.; Jia, L.; Wang, Q.; Xu, G. Um método de seleção de recursos de eliminação de recursos recursivos de máquina de vetor de suporte com base em variáveis de contraste artificiais e informações mútuas. *J. Cromatogr. B* **2012**, 910, 149–155. [RefCruz]
95. Bursac, Z.; Gauss, CH; Williams, DK; Hosmer, DW Seleção proposital de variáveis em regressão logística. *Código fonte Biol. Med.* **2008**, 3, 17. [CrossRef]
96. Leevy, JL; Hancock, J.; Zuech, R.; Khoshgoftaar, TM Detectando ataques de segurança cibernética usando diferentes recursos de rede com alunos lightgbm e xgboost. Em *Proceedings of the 2020 IEEE Second International Conference on Cognitive Machine Intelligence (CogMI)*, Atlanta, GA, EUA, 28–31 de outubro de 2020; páginas 190–197.

-
97. Taha, AA; Hanbury, A. Métricas para avaliação da segmentação de imagens médicas 3D: análise, seleção e ferramenta. BMC Med. Imagem **2015**, *15*, 29. [\[CrossRef\]](#)
98. Rahman, T.; Khandakar, A.; Kadir, MA; Islã, KR; Islã, KF; Mazhar, R.; Hamid, T.; Islã, MT; Kashem, S.; Mahbub, ZB Detecção confiável de tuberculose usando radiografia de tórax com aprendizado profundo, segmentação e visualização. Acesso IEEE **2020**, *8*, 191586–191601. [\[RefCruz\]](#)